

密级：公开



石家莊鐵道大學
SHIJIAZHUANG TIEDAO UNIVERSITY

工学硕士学位论文

(全日制)

基于机器视觉的玻璃幕墙检测 关键技术研究

Research on Key Technologies of Glass Curtain
Wall inspection Based on Machine Vision

培 养 单 位：机械工程学院

专 业：机械电子工程

研 究 生：赵 珂

指 导 教 师：任 杰 教 授

二〇二二年六月

摘要

玻璃幕墙是现代高层建筑的外围护的主要形式。随着玻璃幕墙老化程度的加剧,幕墙玻璃从高空脱落引发的事故时有发生,幕墙安全管理已成为急需解决的问题。迫切需要对幕墙玻璃进行高效检测,及时发现玻璃的损伤,减少玻璃坠落事故发生。本文基于机器视觉的方法,利用数字图像处理技术实现了对玻璃幕墙的损伤检测。完成的工作内容如下:

(1) 研究了幕墙玻璃的自爆、外力冲击以及热炸裂三种典型损伤的灰度、纹理特征等图像特点,提出了基于机器视觉的玻璃幕墙的检测方案。

(2) 幕墙单元面板图像的提取。对图像进行灰度化处理,然后用 Hough 检测和 Harris 检测相结合的方法确定了幕墙单元面板图像位置,再由透视变换提取单元面板图像,获得了边界清晰的单元图像。

(3) 幕墙面板的图像预处理。由滤波去噪和图像增强两部分组成。优化了中值滤波算法,在保证面板损伤信息的基础上缩短了运行时间;优化了灰度拉伸算法,对图像损伤进行了增强,增加了损伤图像的显示比度,获得了清晰的面板图像。

(4) 面板的损伤检测提取。对比了常用的边缘检测算子的效果,选用融合了 SUSAN 算子和区域分裂合并算法进行检测,实现了面板损伤的边缘提取,计算了面板损伤的特征参数。

(5) 基于支持向量机的方法对面板损伤类型进行识别,选取最大方差、方向梯度直方图和灰度共生矩阵的特征对面板损伤类型进行分类训练,实现了面板损伤的分类。最后,基于像素与物像比例关系对损伤的面积进行了估计测量。

关键词: 机器视觉; 玻璃幕墙; 损伤检测; 支持向量机

Abstract

Glass curtain wall is the main form of outer protection of modern high-rise buildings. With the aggravation of the aging degree of glass curtain wall, accidents caused by curtain wall glass falling off from high altitude frequently occur. Curtain wall safety management has become an urgent problem to be solved. There is an urgent need for efficient detection of curtain wall glass, timely detection of glass damage, and reduction of glass falling accidents. In this thesis, based on the method of machine vision, the damage detection of glass curtain wall is realized by using digital image processing technology. The completed work is as follows:

(1) The image characteristics such as grayscale and texture characteristics of three typical damages of curtain wall glass, such as self-explosion, external force impact and thermal explosion, are studied, and a detection scheme of glass curtain wall based on machine vision is proposed.

(2) Extraction of panel images of curtain wall units. The image is processed in grayscale, and then the image position of the curtain wall unit panel is determined by the combination of Hough detection and Harris detection, and then the unit panel image is extracted by perspective transformation, and the unit image with clear boundary is obtained.

(3) Image preprocessing of curtain wall panels. It consists of two parts: filter denoising and image enhancement. The median filter algorithm is optimized to shorten the running time on the basis of ensuring the panel damage information; the grayscale stretching algorithm is optimized to enhance the image damage, increase the display ratio of the damaged image, and obtain a clear panel image .

(4) Edge extraction of panel damage. The effect of the commonly used edge

detection operators is compared, and the fusion of the SUSAN operator and the area splitting and merging algorithm is selected for detection, the edge extraction of the panel damage is realized, and the characteristic parameters of the panel damage are calculated.

(5) Identify the panel damage types based on the support vector machine method, select the features of the maximum variance, the directional gradient histogram and the gray level co-occurrence matrix to classify and train the panel damage types, and realize the panel damage classification. Finally, the damage area is estimated and measured based on the pixel-to-object ratio relationship.

Key words: machine vision, glass curtain wall, damage detection, support vector machine

目录

第一章 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	3
1.2.1 国内研究现状	3
1.2.2 国外研究现状	3
1.3 论文主要研究内容	5
第二章 幕墙玻璃损伤特征分析及检测方法	6
2.1 幕墙玻璃损伤特征分析	6
2.2 幕墙玻璃损伤检测方法	11
2.3 本章小结	14
第三章 幕墙玻璃图像提取方法及预处理	15
3.1 基于角点检测的幕墙玻璃图像提取方法	15
3.1.1 图像灰度化方法比选	15
3.1.2 基于 Hough 检测的边界确定方法	18
3.1.3 基于 Harris 检测的角点确定方法	20
3.1.4 基于透视变换的幕墙玻璃提取方法	23
3.2 幕墙玻璃图像预处理	25
3.2.1 滤波算法比选	25
3.2.2 基于优化冒泡算法的滤波方法	29
3.2.3 图像增强方法比选	32
3.2.4 基于优化灰度拉伸算法的图像增强方法	35
3.3 本章小结	37
第四章 幕墙面板的损伤检测方法	38
4.1 边缘检测算子比选	38
4.2 基于 SUSAN 算子的损伤检测方法	44
4.2.1 区域分裂合并算法	44
4.2.2 融合 SUSAN 算子和区域分裂合并算法的损伤检测方法	45
4.3 本章小结	47

第五章 幕墙面板的损伤类型识别方法	48
5.1 幕墙面板损伤分类	48
5.1.1 支持向量机理论	48
5.1.2 基于 SVM 的幕墙面板损伤类型识别	52
5.1.3 损伤类型识别实验与结果分析	56
5.2 幕墙面板损伤参数计算	58
5.3 本章小结	58
第六章 结论与展望	60
6.1 结论	60
6.2 展望	61
参考文献	62
致谢	66
个人简历、在学期间的研究成果及发表的学术论文	67

第一章 绪论

1.1 研究背景与意义

在建筑外围护结构中，玻璃幕墙的使用越来越广泛，其发生脆性破坏容易坠落伤人，造成一定的安全事故。我国玻璃幕墙出现最多的安全事故是受到损伤而出现玻璃碎粒散落所造成的伤害和破坏，而这种“天降横祸”也为人们的生活带来了一定的安全隐患。

根据前瞻产业研究院发布的《2021-2026 年中国建筑幕墙行业市场前瞻与投资战略规划分析报告》^[1]：就幕墙面积而言，其年产能目前已过亿。根据中国建筑装饰协会统计数据显示，建筑幕墙工程总产值逐年稳定增长，如图 1-1 所示。




图 1-1 2014-2020 年我国建筑幕墙工程产值状况

根据前瞻产业研究院的预测，我国建筑幕墙的工程产值也会在未来几年稳步提升，如图 1-2 所示。依据我国《建筑结构设计可靠性统一标准》^[2]的规定，建筑幕墙的使用年限为 25 年。由此可见，我国玻璃幕墙的使用面积和老化现象会逐年增多。




图 1-2 2022-2026 年我国建筑幕墙行业工程总产值前景预测

随着相关产业技术的发展,装配式幕墙^[3]、光伏幕墙^[4]等新式幕墙不断涌现;搪瓷板、其他人造板材及超薄石材^[5]等材料制造的幕墙也逐渐应用到高层建筑上,实现了建筑幕墙的多元发展。在国内行业技术标准和规范未成熟期间,由于玻璃良品率低^[6]、耐久性等性能不佳^[7],加工工艺不完善且缺少具体的设计规范和施工标准^[8]等原因,导致玻璃幕墙的使用寿命降低,幕墙玻璃破碎甚至整体脱落等事故时有发生。

我国《玻璃幕墙工程技术规范》^[9]规定,在幕墙工程竣工验收一年后,应对其进行一次全面检查。四川省标准规定每层楼的幕墙检测不少于一处,且每类节点不应少于三个^[10]。天津市规定要求在良好的光线下,距玻璃正面约 600mm 处,并采用精度为 0.1mm 的读数显微镜测量缺陷尺寸^[11]。近年来,以无人机^[12]和数字图像处理^[13]为代表的技术,在建筑领域得到了很好的应用,如施工现场扬尘污染源监测^[14]、外脚手架安全检测^[15]等。

玻璃幕墙的损伤检测是十分重要的。其损伤的出现会影响建筑物采光保温的能力,同时从高空坠落的碎片也会造成严重的后果。而对于高层玻璃幕墙建筑^[16],其预埋件和连接件的安装应严格遵守安装流程,并涂抹适量的防腐漆,以简化后续的安全检测工作。目前的人工检测方法,难以准确高效地完成玻璃幕墙安全检测任务。因此,探索一个智能化、高效化的玻璃幕墙损伤检测方法是智慧建筑^[17]发展的必然趋势。

在定期检查玻璃幕墙的健康情况的同时,应加强对其损伤的检测,及时发现损伤并更换以减少事故的发生,保障人身财产安全。同时,智能化的检测方法提高了损伤检测的准确率,缩短了损伤检测的时间,提升了玻璃幕墙损伤检测的效

果，且操作简单方便，所需人力较少。

1.2 国内外研究现状

1.2.1 国内研究现状

刘小根^[18]等人提出了基于光弹法的玻璃缺陷检测方法，此方法能很好的检测缺陷。顾琰斌利用“频率变化比”对夹层玻璃板 PVB 胶进行损伤检测^[19]。刘小根通过振动测试方法研究了隐框幕墙支承结构出现松动、老化和损伤后幕墙玻璃的固有频率变化规律^[20]，该方法检测准确率高，但仪器安装过程繁琐。

王凤喆等人融合了玻璃图像的纹理特征和不变矩特征，提出了基于机器视觉的玻璃缺陷分类方法^[21]，实现了缺陷的检测，该方法受周围环境干扰低，检测速度快，准确率高，容易受图像质量的影响。

卢印举等人结合灰度和纹理特征提出了一种基于双特征高斯混合模型的玻璃缺陷分割方法^[22]，该方法能够保留低对比度的玻璃缺陷。同时，卢印举等人还提出了一种改进高斯混合模型的玻璃缺陷图像分割方法^[23]，这两种方法均提高了玻璃缺陷分割算法的鲁棒性和准确性。

张彩霞等人针对玻璃表面存在的缺陷，提出了一种改进 K 均值聚类算法用于水印的检测，提高了缺陷识别的准确率和检测速度^[24]。王维等人利用光的偏振特性，针对玻璃等透明物体提出了一种基于偏振透射结构光的表面缺陷检测方法^[25]，该方法能够消除灰尘的影响，并可以有效提高系统信噪比。随着建筑行业慢慢地融入科技元素，检测简便、检测效率高的机器视觉法将是高层建筑玻璃幕墙检测的发展方向。

1.2.2 国外研究现状

声发射检测法幕墙已应用于很多场合，如探索不同载荷^[26]、结构间断^[27]等对玻璃纤维材料损伤的影响，该检测方法能够有效地检测玻璃幕墙面板损伤的深度，但对噪声很敏感，容易产生较大的误差。Malpot 等人利用红外线检测汽车玻璃疲劳试验中疲劳应力对下维断裂量的影响^[28]，该方法能够做到对高空玻璃的无损检测，但容易受到温度的干扰，且仅局限于损伤形式的检测，难以检测玻璃幕墙面板损伤的深度。

针对提高玻璃分类性能的问题,从玻璃瓶敲击声信号中提取特征作为分类器的输入,对原有的特征选择算法进行了优化,将特征选择与分类器的训练相结合,采用包装器方法对所选特征进行评价,以 SFLA 算法作为搜索算法,用 BP 神经网络作为分类器,提高了分类性能^[29]。Jisu Park 等人对盖玻片的缺陷检测进行了深入研究,提出了基于深度学习神经网络(DLNN)的缺陷检测系统,该算法在灵活性和性能方面具有优势,引入了一种加权多 DLNN 检测系统,能够有效地利用多通道测量数据,具有较高的检测率^[30]。Koichi Mizukami 等人提出一种用于非导电玻璃钢检测的涡流探头的设计^[31],由于磁场包含有关被测材料介电常数的信息,涡流检测通过检测每个材料完好部分和缺陷部分之间的介电常数差,为检测非导电材料中的缺陷提供了可能性,该探头可以检测出距离玻纤增强塑料试样表面 2mm 处的狭缝缺陷和平底孔。

玻璃在制造过程中产生的表面划痕或在使用阶段出现的表面划痕,如风载碎片的撞击,可能会导致玻璃材料强度显著退化。为了评估玻璃部件的断裂可能性,应该在其生命周期中监测划痕的大小和数量。针对透明玻璃表面划痕检测问题,提出了基于 Mask 和区域卷积神经网络的像素级实例分割模型^[32]。通过定制的自动显微相机扫描系统采集有划痕的图像,建立训练和验证数据集,然后将该模型与 YOLACT 分割方法进行比较,结果表明该模型在检测和分割精度方面都有较好的性能。

采用非接触式数字图像相关(DIC)技术对玻璃幕墙进行了全场表面弯曲变形表征。通过实验装置,获得了被测玻璃面板在风荷载条件下的数字散斑图像序列,然后对玻璃板的全场变形进行了定量计算,并与有限元分析(FEA)和应变仪、数字指示器等传统测量设备的数据进行了比较。结果表明,引入的 DIC 方法不仅能够实现玻璃板的全场弯曲变形测量,而且能够获得与传统方法相比较的测量结果。因此,对玻璃板的全场位移和应变进行了评估,仔细分析了玻璃板在风荷载作用下的表面挠度和曲率,便于表征玻璃幕墙的抗风性能^[33]。

在组合式隐框支撑(UHFS)玻璃幕墙系统中,玻璃幕墙通常暴露在外部风荷载下,因此,基于立体视觉和数字图像相关理论,研究了由连接构件产生的复杂边界约束及其相互作用引起的玻璃板耦合变形,在建立的光学测量系统中利用传统的数字指标和有限元分析(FEA)模型,提供了玻璃板的实际和理论变形信息,研究了玻璃板在实际使用条件下的时空变形行为,从而评估了玻璃板表面的主应变、最大相对挠度(MRD)和应变能密度,上述指标可为 UHFS 幕墙系统中玻璃

的失效风险评估和安全设计提供参考^[34]。

Shigeki Sawamura 等人对脆性玻璃的划伤进行了研究，进行了横向纳米压痕实验，采用一系列结构致密度较低的热压缩石英玻璃，得到了定量划痕硬度与底层玻璃结构之间的关系，试验表明，杨氏模量为观察到的划痕硬度变化提供了一个清晰的理性。在二氧化硅的特殊情况下，产生一定划痕体积所需的能量大约相当于杨氏模量的十分之一。这表明在变形过程中，只有大约十分之一的化学键被破坏。然而，与具有一定比例的二维结构单元、对局部应力具有较强拓扑适应能力的更为复杂的玻璃材料相比，明显背离了这种行为。这为抗刮擦玻璃的拓扑化学工程开辟了一条道路^[35]。

1.3 论文主要研究内容

本文针对幕墙玻璃的损伤检测问题，基于传统的检测算法，对幕墙玻璃损伤检测的关键技术进行了研究，主要内容如下：

1) 幕墙玻璃损伤特征分析

分析幕墙玻璃典型损伤的特征，描述各损伤类型的形状特点等信息；分析幕墙玻璃损伤区域的图像特征，研究了幕墙面板损伤的颜色、纹理、复杂程度等，为后续的损伤分类识别提供了依据，确定幕墙玻璃损伤检测方法。

2) 幕墙玻璃图像提取及预处理

研究幕墙玻璃图像提取方法和预处理算法。对比了相关的算法，然后对滤波算法和图像增强算法进行了优化，提高了幕墙玻璃图像的损伤显示比度，为后续的损伤检测提供基础条件。

3) 幕墙面板图像损伤检测

研究幕墙面板图像的损伤检测方法。对常用的边缘检测算法进行了效果对比，选用效果相对较好的 SUSAN 算法，并针对存在的问题，对其进行了优化，结果表明，优化后的算法提高了检测结果的连续性、准确性和完整性。

4) 幕墙面板损伤图像特征提取及损伤分类

研究幕墙面板损伤分类方法。对损伤图像的特征进行提取，通过基于支持向量机的方法进行损伤分类。最后，对损伤参数进行测量。

第二章 幕墙玻璃损伤特征分析及检测方法

本章研究了幕墙玻璃的损伤特征，对图像特征、灰度特征、纹理特征等进行了综合分析，为后续的损伤分类提供了依据。同时确定了本文的检测方法，为后续损伤识别算法的设计做好了规划。本文所使用的软件平台为 Matlab R2016a。

2.1 幕墙玻璃损伤特征分析

常用的幕墙玻璃种类有钢化玻璃和半钢化玻璃等。我国的玻璃幕墙大都采用的是符合国家标准的钢化玻璃^[36]。玻璃幕墙的框架支撑主要包括明框和隐框，本文研究的是隐框玻璃幕墙，隐框幕墙外表美观，但给检测增加了一定难度。

目前常用的检验方法有两种：表面检查法和内部检查法。前者依靠检测外表面是否有损坏现象进行判定；后者是通过检查内部连接件或支承部位是否有腐蚀或松动现象判断是否损坏。本文的检测方法是基于表面检查法的机器视觉法，通过对拍摄图像的处理，进而判断表面是否有损伤。

（1）幕墙玻璃损伤类型

在幕墙玻璃的损伤类型中，出现频率最高的是自爆、外力冲击和热炸裂。玻璃的损伤多是内部应力集中导致的。当玻璃表面的张应力超过允许的最大范围时，玻璃就会产生类似“蝴蝶斑”状的损伤。即使国内的高水平加工企业中，钢化玻璃也有一定的自爆概率，为 3%~5%，且自爆现象无法预估。现有的方法，如光弹扫描法可以很好的检测自爆源。如图 2-1 所示为钢化玻璃自爆的情形。



图 2-1 钢化玻璃自爆


热炸裂也是玻璃的主要损伤类型之一。长期暴露在阳光下或者受到其他热源的照射后，通常玻璃最薄弱的部位会产生热炸裂，因为最薄弱部位产生的热应力超过了其最大的抗拉强度。一般情况下，热能吸收率较高的玻璃和热反射玻璃最容易发生这种损伤。

当幕墙玻璃边缘部位出现细小的裂纹时，这些裂纹会逐渐受到热应力的影响，进而导致破损现象的发生。热炸裂的损伤通常为细小的裂纹，在光线的照耀下不易被发现，形成的裂纹会无规则地向外扩散，如图 2-2 所示。




图 2-2 玻璃热炸裂

因外力冲击引起的损伤多是外界或人为。不同类型的幕墙玻璃受到外力冲击，呈现的特征不同。普通玻璃受到外力破坏时，损伤会以受力点为中心向外扩散，裂纹与玻璃表面近似垂直。钢化玻璃受到外力冲击破坏时，受力点中心表面有白色粉末状凹陷，以受力点为中心向外发散，如图 2-3（a）所示。夹层玻璃在受到外力冲击时，会形成透明度较低的区域，且会由受力点向外扩散，如图 2-3（b）所示。



图(a) 钢化玻璃外力冲击破坏



图(b) 夹层玻璃外力冲击破坏

图 2-3 外力冲击


(2) 幕墙玻璃的灰度直方图特征

灰度直方图是对图像中像素值频率的统计，反映了图像的灰度变化特征。

图 2-4 所示为玻璃自爆及其对应的灰度直方图，图像中玻璃的碎片呈放射状分布，裂纹多且分布广，是较容易识别的一种缺陷。从直方图中可以看出，波峰在中间偏右的位置，说明图像中有很多高亮部分，而整体高亮部分与深色部分所占比重相当，颜色反差较大，对比度较明显。



(a) 玻璃自爆



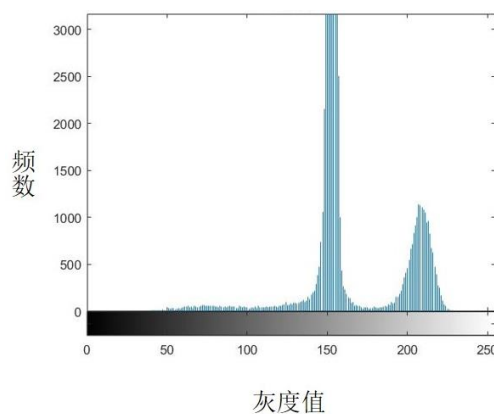
(b) 灰度直方图

图 2-4 玻璃自爆及灰度直方图

图 2-5 所示为玻璃热炸裂及其对应的灰度直方图。热炸裂损伤的图像中，裂纹较长较少且不明显，直方图中间偏右部分有两个波峰，说明图像中有两个高亮区域，对应了图像中的两条裂纹。图像整体没有较暗的部分，颜色分布较均匀，在灰度直方图中较容易判断。



(a) 玻璃热炸裂

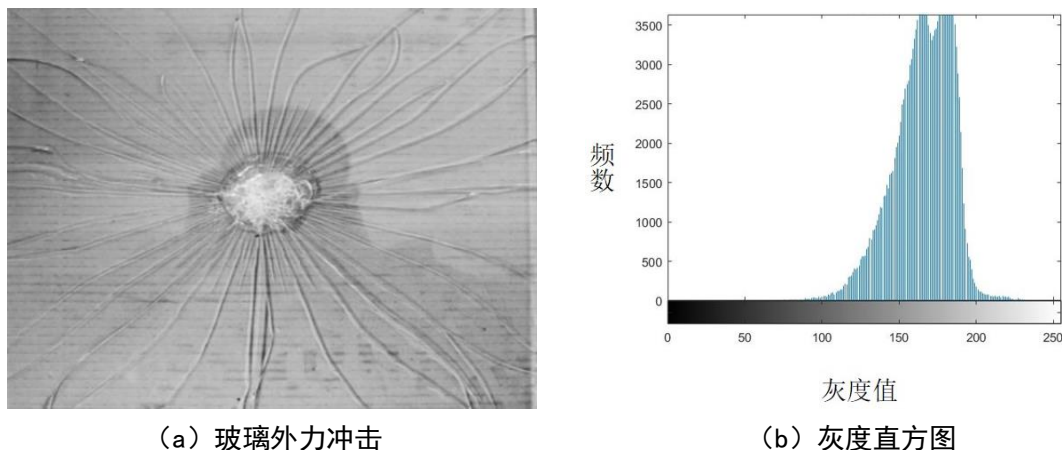


(b) 灰度直方图

图 2-5 玻璃热炸裂及灰度直方图

图 2-6 所示为外力冲击及其对应的灰度直方图。由外力冲击引起的凹陷部分同周围会产生色差，直方图显示图像的整体呈灰亮色，色差不是很大。直方图的

右侧有一部分的像素堆积分布，在图像中表现为高亮区域和白色的凹陷部分，引起的裂纹在直方图中不容易识别，凹陷部分较容易识别。




(a) 玻璃外力冲击

(b) 灰度直方图

图 2-6 玻璃外力冲击及灰度直方图

(3) 幕墙玻璃的方向梯度直方图特征

方向梯度直方图特征是目标检测领域应用最广泛的特征，可以很好的描述图像的纹理特征和空间布局。如图 2-7~2-9 所示为自爆、热炸裂和外力冲击的方向梯度直方图。



(a) 自爆的方向梯度直方图

(b) 局部 A 的放大图

图 2-7 玻璃自爆的方向梯度直方图

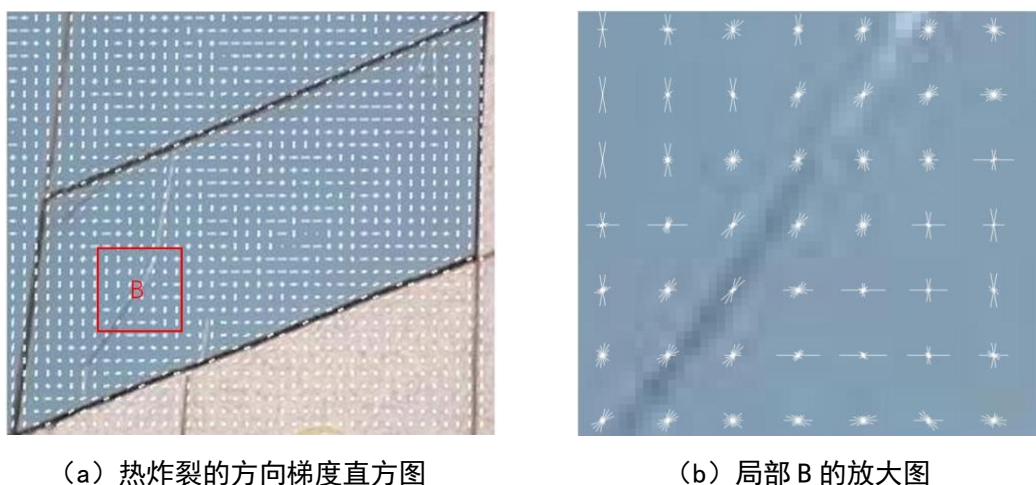


图 2-8 玻璃热炸裂的方向梯度直方图

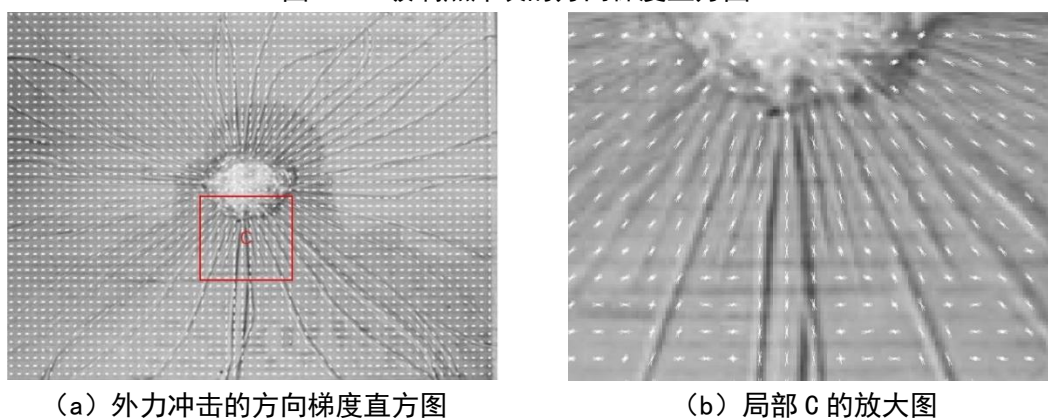


图 2-9 玻璃外力冲击的方向梯度直方图

通过对三种损伤类型方向梯度直方图的对比，自爆、外力冲击和热炸裂的损伤复杂程度和图像的纹理复杂程度依次降低，且损伤的形状、走向等纹理特征可以被方向梯度直方图表述出来。这些特征可用作后续的损伤类型识别。

(4) 幕墙玻璃的灰度共生矩阵特征

灰度共生矩阵表明了相同灰度级像素之间的位置分布特征，是图像综合信息的体现。通常为了表达的更直观，用提取的能量、熵和相关性的特征参数表述，如表 2-1~2-3 所示。

表 2-1 灰度共生矩阵提取的能量特征对比

能量	0°方向	45°方向	90°方向	135°方向
自爆	0.145681	0.124956	0.131287	0.132326
热炸裂	0.580550	0.561047	0.598492	0.551021
外力冲击	0.211841	0.151846	0.165766	0.172115

由表 2-1 能量特征的对比, 热炸裂、外力冲击、自爆的特征值依次降低, 能量值越大, 表明图像的灰度分布越均匀且纹理变化规则。

表 2-2 灰度共生矩阵提取的熵特征对比

熵	0°方向	45°方向	90°方向	135°方向
自爆	3.138131	3.570877	3.410076	3.455314
热炸裂	1.093913	1.155610	1.065793	1.219171
外力冲击	1.896670	2.260735	2.164191	2.117891

由表 2-2 熵特征的对比, 自爆、外力冲击、热炸裂的特征值依次降低, 熵值越大, 表明图像越复杂。

表 2-3 灰度共生矩阵提取的相关性特征对比

相关性	0°方向	45°方向	90°方向	135°方向
自爆	0.095263	0.088263	0.090674	0.090776
热炸裂	1.690804	1.583154	1.592935	1.247521
外力冲击	0.899607	0.783695	0.822748	0.0841568

由表 2-3 相关性特征的对比, 热炸裂、外力冲击、自爆的特征值依次降低, 相关性的值越大, 纹理方向越明显。

由以上分析可知, 自爆的损伤图像中, 其灰度分布不均匀, 纹理变化无规则且复杂度最高, 其次是外力冲击, 热炸裂的损伤图像灰度分布相对较均匀, 且复杂度最低。幕墙玻璃的三种损伤类型在复杂程度、纹理变化规则程度和灰度分布均匀程度上从高到低的排列顺序依次为: 自爆、外力冲击、热炸裂。

通过无人机进行采集的图片会受到外界环境中太阳光和风速的影响。若太阳光较强烈, 图像的整体亮度会提升, 灰度直方图的波峰会降低, 且向右移动; 方向梯度直方图特征不会发生较大的变化, 图像的灰度共生矩阵中的能量特征值会变大, 熵特征值不会发生较大的变化, 相关性的值会发生些许变化, 导致纹理方向变弱。但总体的特征变化不会对后续的特征分类造成较大的影响, 且后续的图像灰度化处理会降低部分光线的影响; 若风速较大, 会导致采集的图片位置不佳, 但不会对图片的特征分析产生影响, 且后续的透视变换处理可以将倾斜图片中的单元面板提取出来。

2.2 幕墙玻璃损伤检测方法

在分析了幕墙玻璃损伤的图像特征、直方图特征及灰度共生矩阵特征的基础上，确定了损伤检测的流程，如图 2-10 所示，包括图像提取、图像预处理、图像边缘检测和损伤类型识别四个部分。整体流程是在 Matlab 环境下进行的。

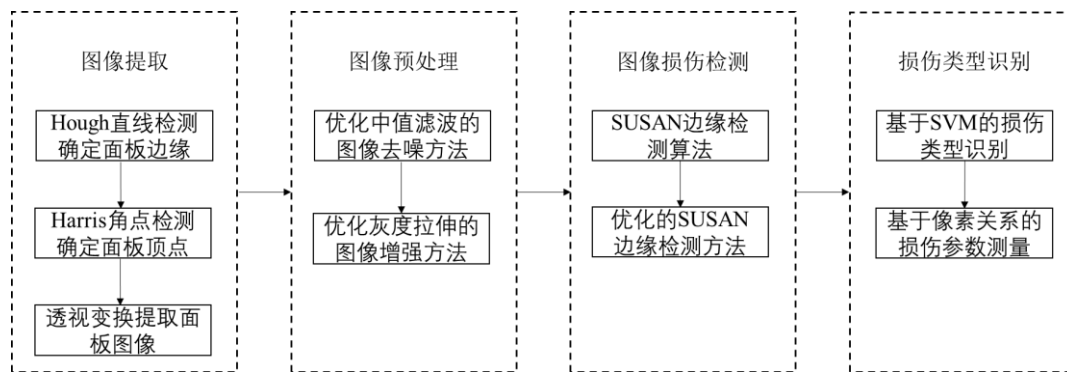


图 2-10 损伤检测流程

1) 图像提取。通过定位幕墙玻璃的角点和直线边缘，确定幕墙玻璃各个单元的位置，然后把幕墙单元图像提取出来，减少图像的运算量同时去除幕墙边框等干扰因素，方便后续处理。

2) 图像预处理。对提取出的图像进行滤波和增强处理，在现有算法的基础上进行了优化。优化后的中值滤波算法缩短了运行时间，优化后的灰度拉伸算法加深了图像损伤的显示比度，更好的突出了缺陷。

3) 图像边缘检测。边缘检测的结果为图像中灰度突变的部分，此即为需要检测的损伤。对传统的边缘检测方法进行结果对比，选取合适的检测方法。在 SUSAN 算法的基础上融合了区域分裂合并算法，加强了图像损伤的连续性和完整性。

4) 损伤类型识别。提取三种损伤和非损伤样本的方向梯度直方图、灰度共生矩阵等特征送入向量机，利用支持向量机的方法对损伤进行识别分类。最后通过图像像素对损伤参数进行测量。

本文的技术路线图如图 2-11 所示。

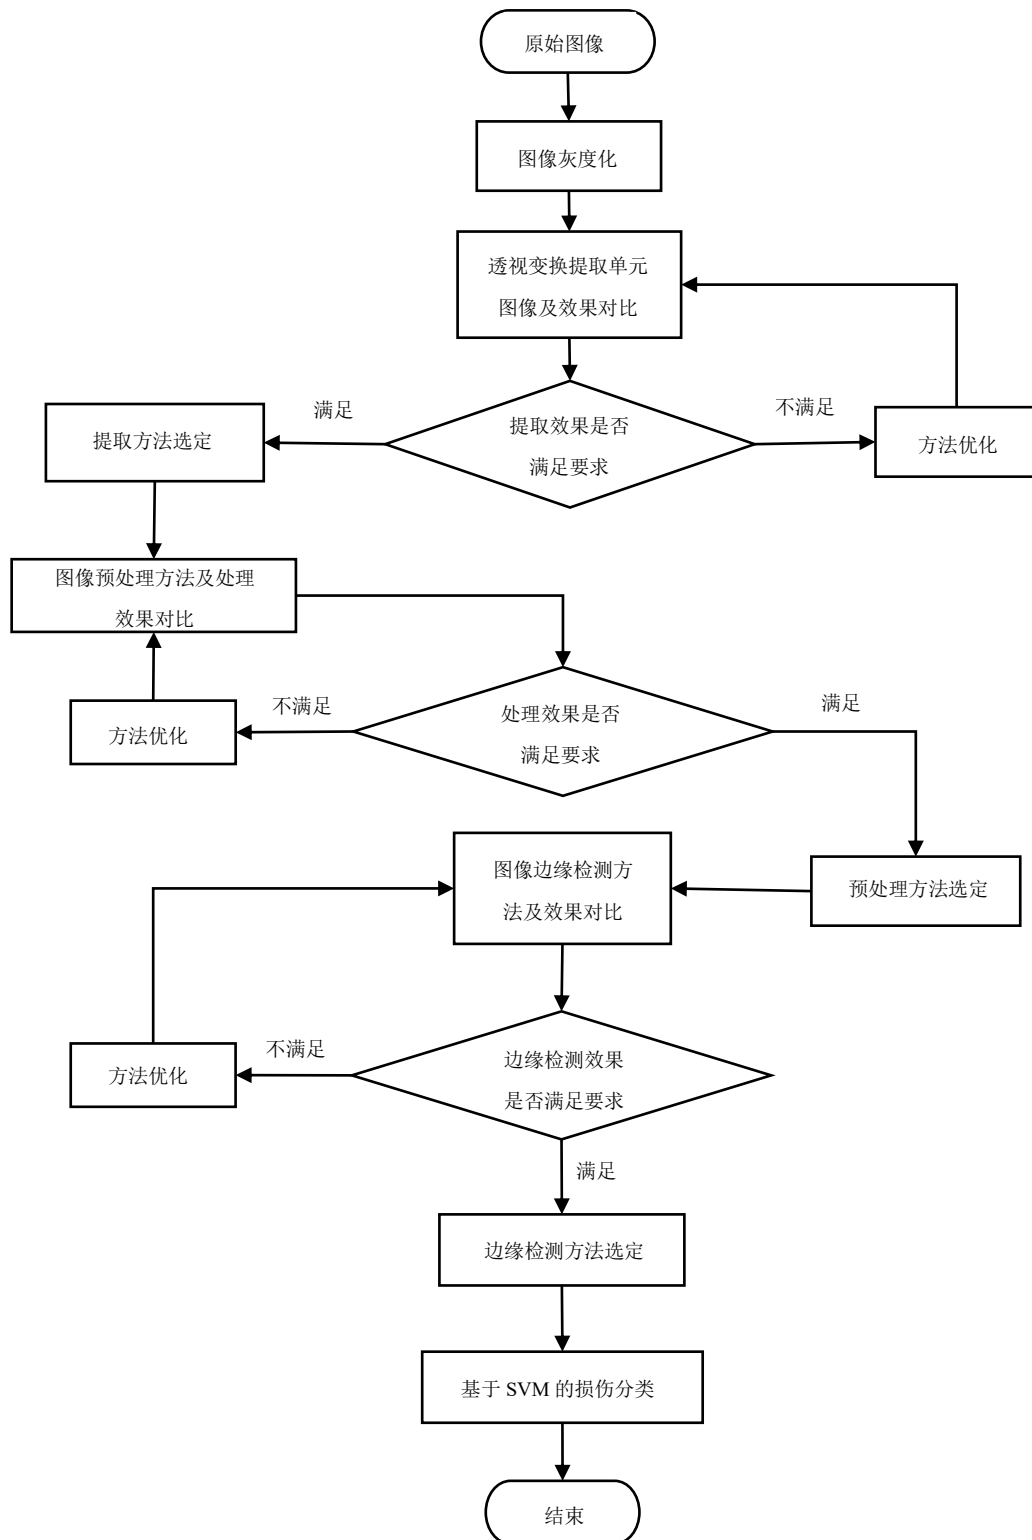


图 2-11 技术路线图

2.3 本章小结

本章在基于幕墙玻璃图像特点的基础上,分析了自爆、热炸裂和外力冲击三种类型的损伤特征和损伤图像的特点,提取了图像直方图和灰度共生矩阵的特征参数,提出了本文的技术路线图,确定了检测流程和方法。图像提取方面,在 Harris 角点检测的基础上,结合 Hough 直线检测确定幕墙单元面板位置,再利用透视变换提取单元图像;图像预处理方面,对常用的滤波算法和图像增强方法进行了效果对比,并在原有的基础上进行了优化;图像边缘检测方面,对传统的边缘检测方法进行了效果对比,选定了合适的方法,在 SUSAN 检测的基础上融合了区域分裂合并算法,使得提取的损伤更清晰完整;损伤类型识别方面,基于支持向量机的方法对损伤类型进行识别,通过损伤部位像素占比与物像比例关系计算损伤面积。

第三章 幕墙玻璃图像提取方法及预处理

本章在第二章分析损伤特征的基础上，对现有的算法进行了实验分析和对比，针对结果中出现的问题，对算法进行了部分优化，确定了幕墙玻璃的提取及图像预处理方法。

3.1 基于角点检测的幕墙玻璃图像提取方法

幕墙玻璃的边界部位可能在检测过程中被检测出来，这增加了图像处理的复杂程度和时间。为避免无关因素的干扰，提高幕墙玻璃损伤提取的效率和准确率，在 Harris 检测的基础上，结合 Hough 直线检测的方法，确定幕墙玻璃单元面板的位置，然后再由透视变换的方法将玻璃幕墙中的单元面板逐一提取出来。

3.1.1 图像灰度化方法比选

图像灰度化是将彩色图像转换为灰度图像。灰度化的目的是尽量多的保留彩色图像中有意义的信息，使得到的灰度图像在视觉上产生更好的效果^[37]。灰度化算法属于基于色彩信息对图像进行增强的一类算法^[38]。在保证图像特征的基础上，将彩色图像转化为数据量小，更易于处理的灰度图像。

在图像处理过程中，直接使用 RGB 彩色模型会产生很大的计算量和运算时间。因此，在处理幕墙玻璃图像之前，需要先对图像进行灰度化处理。传统的处理方法有以下三种：

1) 最大值法

将图像中 R,G,B 的值都等于三个中最大的一个，其结果会形成较高亮度的图像。处理结果如图 3-1(b)所示。

$$f(i, j) = \max(R(i, j), G(i, j), B(i, j)) \quad (3-1)$$

2) 平均值法

求出 R,G,B 三个值的平均值， $R=G=B=(R+G+B)/3$ 。处理结果如图 3-1(c)所示。

$$f(i, j) = \frac{R(i, j) + G(i, j) + B(i, j)}{3} \quad (3-2)$$

3) 加权平均值法

与平均值法不同的是 R,G,B 三个值前的系数, 即 $R=G=B=WR+VG+UB$, 经过实验和理论证明当权重为 $W=0.30, V=0.59, U=0.11$ 时, 得到的灰度图像较合理。处理结果如图 3-1(d)所示。


$$f(i, j) = 0.30R(i, j) + 0.59G(i, j) + 0.11B(i, j) \quad (3-3)$$



(a) 原图



(b) 最大值法



(c) 平均值法



(d) 加权平均值法

图 3-1 灰度化处理结果

经过处理之后的图像, 通常会与原图像不同, 因此需要对处理后的图像进行评价, 以确定处理结果的好坏。本文选用峰值信噪比(PSAN)、均方误差(MSE)、均值和平均梯度作为评价指标来衡量图像的质量优劣。

1) MSE

设一幅图像的像素值为

$$\{x(i, j), 0 \leq i \leq M-1, 0 \leq j \leq N-1\} \quad (3-4)$$

M 和 N 表示图像的宽度和高度, $x(i, j)$ 表示位于 (i, j) 处的像素值, 以下各式均与此相同。压缩后重建图像的像素值为

$$\{\hat{x}(i, j), 0 \leq i \leq M-1, 0 \leq j \leq N-1\} \quad (3-5)$$

则误差图像的像素值为

$$\{e(i, j) = x(i, j) - \hat{x}(i, j), 0 \leq i \leq M-1, 0 \leq j \leq N-1\} \quad (3-6)$$

那么均方误差表示为

$$MSE = \frac{1}{MN} \sum_{i=0}^{M-1} \sum_{j=0}^{N-1} e^2(i, j) = \frac{1}{MN} \sum_{i=0}^{M-1} \sum_{j=0}^{N-1} [x(i, j) - \hat{x}(i, j)]^2 \quad (3-7)$$

可以简写为

$$MSE = \frac{1}{m} \sum_{i=1}^m (y_i - y'_i)^2 \quad (3-8)$$

结果得到的数值越小，表明图像的质量越好。

2) PSNR

设

$$x_{\max} = 2^K - 1 \quad (3-9)$$

则峰值信噪比为

$$PSNR = 10 \lg \frac{x_{\max}^2}{MSE} = 10 \lg \left[\frac{x_{\max}^2 MN}{\sum_{i=0}^{M-1} \sum_{j=0}^{N-1} [x(i, j) - \hat{x}(i, j)]^2} \right] (dB) \quad (3-10)$$

通常在处理图像的过程中，对于 8 位的二进制图像， $K=8$ ， $x_{\max}=255$ ，代入得

$$PSNR = 10 \lg \frac{255^2}{MSE} = 10 \lg \left[\frac{255^2 MN}{\sum_{i=0}^{M-1} \sum_{j=0}^{N-1} [x(i, j) - \hat{x}(i, j)]^2} \right] (dB) \quad (3-11)$$

PSNR 值的大小可以直接反映图像的好坏，只越大，表明图像失真越小，图像质量越好。

3) 均值

图像的均值是评价图像质量的标准之一，设待评价图像为 F ，其均值计算公式为

$$u = \frac{1}{MN} \sum_{i=0}^{M-1} \sum_{j=0}^{N-1} F(i, j) \quad (3-12)$$

4) 平均梯度

作为判断图像清晰度的指标之一，平均梯度用来反映图像中的纹理特征变化，其计算公式为

$$\nabla G = \frac{1}{MN} \sum_{i=0}^{M-1} \sum_{j=0}^{N-1} \sqrt{\Delta x F(i, j)^2 + \Delta y F(i, j)^2} \quad (3-13)$$

将通过最大值法、平均值法和加权平均值法得到的结果与通过调用系统函数实现的结果进行对比，如表 3-1 所示。

表 3-1 灰度化处理的结果对比

灰度化方法	MSE	PSNR	u	∇G
最大值法	154.9787	26.2281	222.1600	0.0106
平均值法	3.3554e+03	12.8743	176.1096	0.0045
加权平均值法	0.4830	51.2912	213.9444	0.0103

通过以上结果的综合对比发现，加权平均值法效果较好，保留了更多的图像细节，失真较少，且像素分布更加均匀，对图像的处理效果更好。通过对比可得，平均值法效果最差，加权平均值法的 MSE 值比最大值法小，均值和平均梯度相当，因此，灰度化处理适合选用加权平均值法。

3.1.2 基于 Hough 检测的边界确定方法

在直线提取的方法中，Hough 检测因抗干扰能力强的优点成为最常用的方法之一，而且其受图像噪声的影响较小。Hough 检测利用图像局部块线索定位目标，且图像局部特征通常对光照变化鲁棒，因此能有效克服目标形变、部分遮挡及光照变化等因素的影响^[39]。

在两个坐标空间中，线与点是一一对应的，如图 3-2 所示，即图像空间中的一条线对应参数空间单独的一个点；图像空间中的线也对应参数空间中的一个点。在参数空间 $O-kb$ 平面上与直线相交最多的点，在 $O-xy$ 平面上所对应的直线就是我们的解。




图 3-2 图像空间与参数空间的对应关系

通常在实际应用中，一般采用极坐标系作为参数空间让变换域变得有意义。极坐标系中的直线如式 3-14 所示：

$$r = x \cos \theta + y \sin \theta \quad (3-14)$$

式中，数对 (r, θ) 是原点到直线的距离的向量， r 表示向量长度， θ 表示向量方向。如图 3-3 所示为两个坐标空间的转换过程。





图 3-3 图像空间与极坐标参数空间的转换

极坐标参数空间中的曲线相交的次数越多，画出的图像越饱满，检测的结果越准确。

如图 3-4 所示是 Hough 检测的结果。



(a) 原图



(b) Hough 检测

图 3-4 Hough 检测结果

由检测结果可以看出，Hough 检测对边界的漏检情况比较少，基本能完整准确的检测边界信息且确定的边界位置清晰，受噪声影响较小。

3.1.3 基于 Harris 检测的角点确定方法

角点是图像处理领域中最重要的一种局部特征，在图像匹配、目标跟踪等很多方面有重要意义。同时该算法有很好的区分性和重复性^[40]。

角点的检测方法有两类：一是图像边缘，二是图像灰度。前者计算量较大，需要提前进行图像的编码操作，典型方法有 CCS。后者是通过计算点的曲率及梯度来检测角点，避免了第一类方法存在的缺陷，是目前的研究重点，典型方法有 Moravec 算子、Harris 算子等。

本文采用第二种方法，使用的是 Harris 算子。

Harris 检测角点的原理如下：选用一个合适的窗口在图像上进移动，若窗口内的灰度没有发生变化，则窗口所检测的部位没有角点，如图 3-5(b)所示；若窗

口内的灰度发生了较大的变化，则检测部位存在角点，如图 3-5(a)所示；若窗口内的灰度在某一个方向上变化较大，而在其他方向没有变化，则检测部位存在直线或线段，如图 3-5(c)所示。




图 3-5 Harris 角点检测原理

当检测的窗口发生移动时，窗口内的像素点灰度变化如式 3-15 所示：

$$E(u, v) = \sum_{x, y} w(x, y) [I(x+u, y+v) - I(x, y)]^2 \quad (3-15)$$

$[u, v]$ 是窗口的位移量； (x, y) 是窗口所对应的像素位置； $w(x, y)$ 是窗口函数，有时我们会用二元高斯函数表示窗口函数。上式还可以进一步演化如下：

$$\begin{aligned} \sum [I(x+u, y+v) - I(x, y)]^2 &\approx \sum [I(x, y) + uI_x + vI_y - I(x, y)]^2 = \\ \sum u^2 I_x^2 + 2uv I_x I_y + v^2 I_y^2 &= \sum [u \quad v] \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix} \begin{bmatrix} u \\ v \end{bmatrix} = \\ [u \quad v] \left(\sum \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix} \right) \begin{bmatrix} u \\ v \end{bmatrix} \end{aligned} \quad (3-16)$$

于是式 3-15 可以表示为

$$E(u, v) \cong [u \quad v] M \begin{bmatrix} u \\ v \end{bmatrix} \quad (3-17)$$

式 3-17 中的矩阵 M 为

$$M = \sum_{x, y} w(x, y) \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix} \quad (3-18)$$

当矩阵的特征值较大时，则检测部位中存在角点；当特征值一个较小，一个较大时，检测部位中存在边缘；当特征值较小时，检测部位没有角点和边缘。通

常用式 3-19 进行判断：

$$R = \det M - \alpha(\text{trace}M)^2 \quad (3-19)$$

其中， α 为常量，一般取值为 0.04~0.06， $\det M = \lambda_1 \lambda_2$ ， $\text{trace}M = \lambda_1 + \lambda_2$ ， λ_1 和 λ_2 为矩阵 M 的特征值。然后在邻域内进行非极大值抑制，局部最大值点即为图像中的角点。

如图 3-6 所示是 Harris 检测的结果：




图 3-6 Harris 检测结果

由以上的结果可以看出，Harris 检测并不能很好的检测出我们需要的角点位置，因此对该方法进行了优化，在 Harris 检测的基础上融合了 Hough 检测进行角点检测，在确保图像的边界直线完全被检测出来的前提下，Harris 检测能很好的得到各个角点的位置信息。如图 3-7 所示为优化后的结果。最终结果如图 3-8 所示。




图 3-7 优化 Harris 后的检测结果




图 3-8 Harris 检测的最终结果

由结果可知，结合了 Hough 检测后，Harris 检测可以较准确的提取出幕墙面板的角点位置且对图像亮度和对比度的变化不明显，对噪声的抗干扰能力较强，为后续的透视变换提取工作提供准确的单元面板位置信息。

3.1.4 基于透视变换的幕墙玻璃提取方法

透视变换^[41]是将一个平面通过一个投影矩阵投影到另一个平面上，原理如图 3-9 所示。通过无人机进行拍摄而获得的图像会存在部分失真现象，为了能更好的对图像进行损伤检测，需要对图像进行校正，基于透视变换的方法将校正后的单元面板图像提取出来。




图 3-9 透视变换原理

透视变换通用公式为

$$\begin{bmatrix} x' & y' & w' \end{bmatrix} = \begin{bmatrix} u & v & w \end{bmatrix} \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} \quad (3-20)$$

$$x = \frac{x'}{w'}, y = \frac{y'}{w'} \quad (3-20)$$

其中 u, v 代表原图坐标, x, y 为经过透视变换后的坐标, 变换矩阵为 3×3 , 它可以拆分为四个部分: $\begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}$ 为线性变换矩阵, $\begin{bmatrix} a_{31} & a_{32} \end{bmatrix}$ 为平移矩阵, $\begin{bmatrix} a_{13} \\ a_{23} \end{bmatrix}$ 为产生透视变换的矩阵, $a_{33} = 1$, 因此, 变换公式也可由式 3-21 表示:

$$\begin{aligned} x &= \frac{x'}{w'} = \frac{a_{11}u + a_{12}v + a_{31}}{a_{13}u + a_{23}v + a_{33}} \\ y &= \frac{y'}{w'} = \frac{a_{12}u + a_{22}v + a_{32}}{a_{13}u + a_{23}v + a_{33}} \end{aligned} \quad (3-21)$$

由公式可知, 只需要四个坐标对, 就可求得式 3-21 中的八个参数, 即可求得透视变换矩阵, 然后对原图进行透视变换。四个坐标对即是前述所求的 Harris 检测的单元面板的四个顶点。

幕墙面板的提取方法过程如图 3-10 所示:




图 3-10 图像提取过程

最后的提取结果如图 3-11 所示:




图 3-11 幕墙面板提取结果

在确定了幕墙单元面板的角点位置和边界位置后，通过透视变换提取了单元图像，可以看出该方法能够有效准确地提取幕墙单元图像。直线检测的准确性与提取结果有一定的相关性，提取结果的边界会受到一定的影响，有可能会影响后续的处理过程。

3.2 幕墙玻璃图像预处理

在幕墙单元面板图像提取的基础上，对提取的图像进行滤波去噪和图像增强。目的是为了滤除部分干扰和改善图像质量。本文的方法可以有效去除噪声，提高图像损伤的显示比度，把损伤和背景较好地分离出来。

3.2.1 滤波算法比选

图像滤波是图像处理中重要的一个步骤，一直在进行优化和改进，目的是抑制图像中存在的噪声，以减小对后续处理过程的影响，提高处理结果的准确性。图像的滤波去噪具有重要的研究意义和实用价值^[42]。

长期暴露在太阳和空气中的玻璃幕墙因为高温的原因，多会产生均匀分布

的高斯噪声,会对后续处理产生影响。常用的滤波方法有均值滤波和中值滤波。

1) 均值滤波

均值滤波^[43]可以滤除图像中的锐利噪点,对图像进行平滑操作。均值滤波属于线性滤波,是用所选用模板像素值的均值代替原图中的像素值,即选择一个由其相邻的八个或更多像素组成的模板,求模板中所有像素的均值,再把该均值赋予原图像中待处理的像素点,即

$$g(x, y) = \frac{\sum f(x, y)}{m} \quad (3-22)$$

式中, m 为所选模板中总的像素个数, $f(x, y)$ 为模板中的像素值, $g(x, y)$ 为待处理的像素值。均值滤波的原理图如图 3-12 所示。图中左侧深色的部分为待滤波的部分,右侧深色部分为滤波后的结果,每一个像素点的周围有八个相邻的像素点,如左侧深色部分左上角的数字 2,滤波后的结果为 $(1+2+1+1+2+2+5+6+7)=3$,滤波后 2 的位置被 3 代替,依次计算就得到右侧的结果。




图 3-12 均值滤波原理图

均值滤波可以滤除图像中与滤波模板相比较小的像素区域,使图像模糊以便得到感兴趣物体的粗略描述。其缺点是图像的细节也会被破坏,从而使图像变得模糊。

2) 中值滤波

中值滤波属于非线性滤波,处理效果好但计算量大且耗时长^[44]。基本原理与均值滤波类似,是将所选模板的中值取代模板中的待处理点,从而达到消除孤立的噪声点的效果。

通常用二维序列来描述数字图像,因此对图像的中值滤波其实是对二维数据序列的滤波,关键在于寻找中值滤波中用来代替的中值,如一个一维序列{0,

3, 4, 0, 7}, 进行排序后为{0, 0, 3, 4, 7}, 则其中值为 3。中值滤波就是让 3 代替原先的 4。

中值滤波的窗口通常为 3x3、5x5、7x7 等, 窗口的形状也可能会影响滤波效果。因此, 窗口的选择很重要^[45]。如图 3-13 所示为常用的窗口类型, 有圆形、菱形、叉形等。不同的图像需要用不同的窗口处理, 一般情况下, 方形或圆形窗口用来处理含有轮廓线较长的物体的图像; 十字形窗口用来处理含有尖角物体的图像。

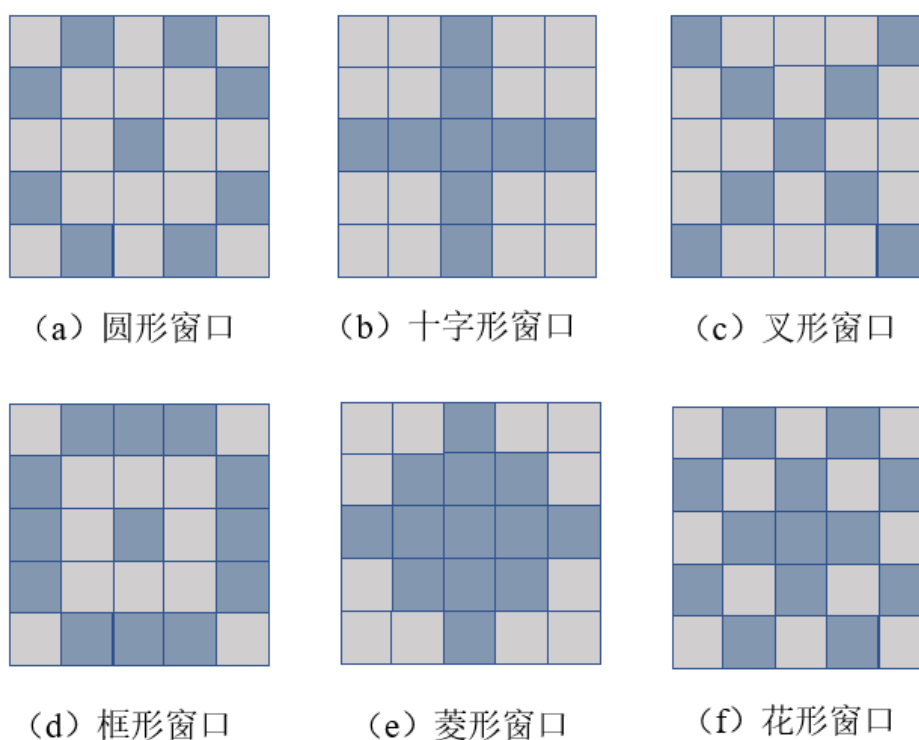


图 3-13 5x5 中值滤波窗口形状

中值滤波的原理图如图 3-14 所示。图中左侧深色部分的中心像素值 1 与周围像素值差距较大, 是需要进行滤波的像素值, 对其周围像素值大小进行排序, 结果为{1, 3, 7, 12, 23, 31, 32, 43, 43}, 排序后的中值为 23, 代替原先的 1, 便得到滤波后的结果, 其他像素点的滤波与此相同。

10	9	4	7	2
4	31	12	23	30
5	43	1	32	8
54	7	3	43	4
23	76	56	45	9

→

10	9	4	7	2
4	31	12	23	30
5	43	23	32	8
54	7	3	43	4
23	76	56	45	9

图 3-14 中值滤波原理

3) 去除孤立噪声点

图像中出现的孤立噪声点可能会影响识别的准确性。中值滤波相比于均值滤波能更好的去除孤立的噪声点，如图 3-15 和图 3-16 的对比。

图 3-15 所示为均值滤波滤除孤立噪声点的过程。图 a 的中心点像素值为 0，与周围的像素值 10 有很大的差距，经过平滑处理后得到图 c，可以看出中心点的像素值与周围像素值的差距减小，但是周围像素值也受到了平滑处理的影响，也并未完全去除孤立噪声点。

10	10	10	10	10
10	10	10	10	10
10	10	0	10	10
10	10	10	10	10
10	10	10	10	10

a

10	10	10	10	10
10	8	8	8	10
10	8	8	8	10
10	8	8	8	10
10	10	10	10	10

b

9	9	9	9	9
9	9	9	9	9
9	9	8	9	9
9	9	9	9	9
9	9	9	9	9

c

图 3-15 均值滤波消除孤立噪声点

图 3-16 所示为中值滤波滤除孤立噪声点的过程，可以看出在消除孤立噪声点的同时并没有对周围其他像素产生影响。如图 3-17 所示，中值滤波也可以很好的消除连续的离散点。

10	10	10	10	10
10	10	10	10	10
10	10	0	10	10
10	10	10	10	10
10	10	10	10	10

a

10	10	10	10	10
10	10	10	10	10
10	10	10	10	10
10	10	10	10	10
10	10	10	10	10

b

图 3-16 中值滤波消除孤立噪声点

10	10	10	10	10
10	10	0	10	10
10	10	0	0	10
10	0	0	10	10
10	10	10	10	10

a

10	10	10	10	10
10	10	10	10	10
10	10	10	10	10
10	10	10	10	10
10	10	10	10	10

b

图 3-17 中值滤波消除连续噪声点

由以上分析对比，可以得出中值滤波相比均值滤波能更好的滤除图像中孤立或连续的噪声点，避免了均值滤波使图像变得模糊的问题。因此，幕墙玻璃的滤波处理可以选用中值滤波。滤波结果对比如图 3-18 所示。




图 3-18 滤波结果对比

3.2.2 基于优化冒泡算法的滤波方法

在交换排序的算法中，最常用的一种是冒泡排序^[46]。首先将相邻位置的元素值进行大小对比，若左侧的值大于右侧，则这两个元素互换位置，若小于或等于右侧值，则位置不变。如图 3-19 所示是一个待排序的序列。




图 3-19 待排序的序列

第一轮排序从第一个数 4 开始，从左向右依次比较大小，4 比 5 小，所以 4 的位置不变。第二个数 5 开始向右移动比较，5 比 3 大，那么两个数就互换位置，5 继续向右比较。若比下一个数小，则位置不变，下一个数开始向右移动；若比下一个数大，则互换位置，依次类推，第一轮排序过程如图 3-20 所示。

以后的每一轮排序依旧从第一个数开始，方法同第一轮相同，最后排序的结果如图 3-21 所示。

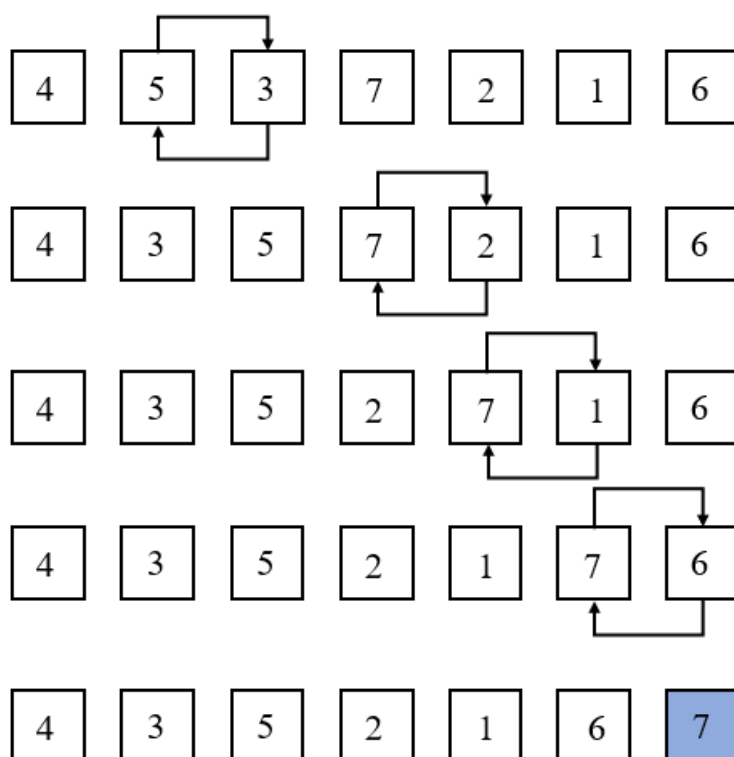


图 3-20 第一轮排序结果




图 3-21 第 2-7 轮排序结果

该算法的每一轮进行过程中都含有所有元素，总共遍历 $(n-1)$ 轮。即使在顺序已经排好的情况下，仍然全部遍历完后才会停止，这样运算量和运行时间都会增加，因此，对冒泡算法进行了优化，如图 3-22 所示。

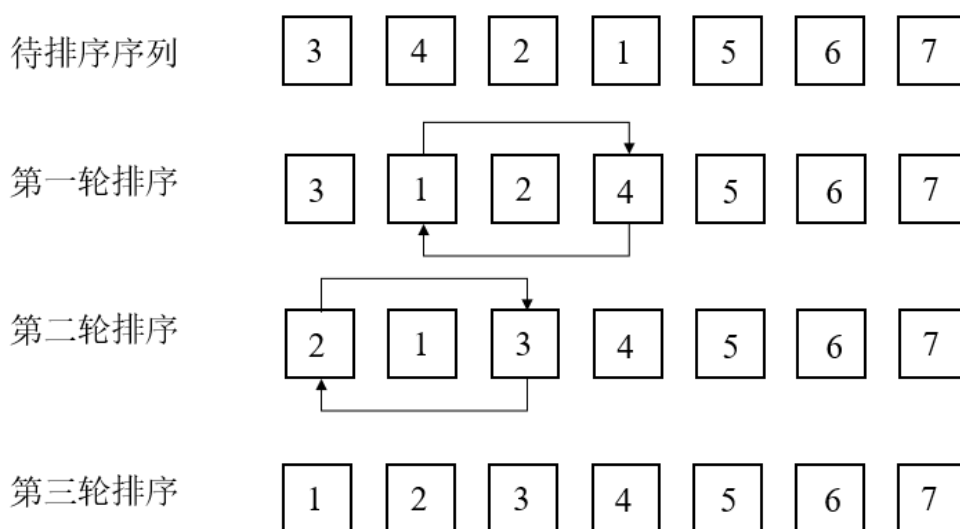


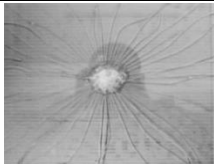

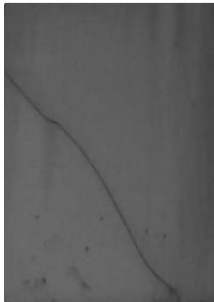


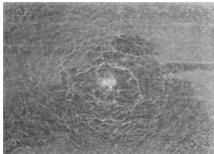
图 3-22 优化的冒泡算法

对冒泡算法的优化是对排序方法的优化，解决思路是在进行完 $n-1$ 轮之前，每进行一轮排序就进行一次有序判断，若有一轮顺序没有发生变化，则说明已经有序，无需进行接下来的几轮。如图 3-22 所示，第一轮排序只交换 4 和 1，第二轮只交换 3 和 2，在第三轮交换 3 和 1 的位置后，很明显第四轮已经排好序了，

后面的两轮就没有必要进行了，这样可以节省一部分时间。

在中值滤波的基础上加入优化的冒泡排序算法，可以节省选取中值的时间，优化前后结果如表 3-2 所示：

表 3-2 优化前后结果对比

中值滤波	运行时间 /s	优化后的 运行时间/s	中值滤波	运行时间 /s	优化后的 运行时间/s
	1.248806	1.053670		1.475437	0.845055
	0.969110	0.727358		0.889558	0.714437
	1.033409	0.746290		1.517505	1.070720

由优化前后对比结果可以看出，在保证滤波质量的前提下，优化后的中值滤波运行时间较之前有所缩短，此外运行时间的长短与图像的质量也有一定的关系，图像清晰且损伤少的图像运行时间明显较短。

3.2.3 图像增强方法比选

图像的质量因室外光照、采集过程、线路传送等种种原因降低了，因此要对图像质量进行改善^[47]，以便于后续对图像的分析。常用的方法是图像增强。

在图像增强技术中，常用的方法是灰度拉伸。灰度拉伸的目的是为了改善图像的质量，使图像的显示效果更加清晰，提高图像的显示比度，有选择的突出图像感兴趣的特征。

目前常用的灰度拉伸算法有分段线性灰度拉伸和直方图均衡化。

1) 分段线性灰度拉伸:

该方法可以把图像中自己不需要的灰度值扩展到自己需要的灰度范围, 扩展范围可以根据图像或者自己的要求而定, 如图 3-23 所示。表达式可以表示为:

$$f(x) = \begin{cases} \frac{c}{a}x, & x < a \\ \frac{d-c}{b-a}(x-a) + c, & a \leq x \leq b \\ \frac{255-d}{255-c}(x-b) + d, & x > b \end{cases} \quad (3-23)$$




图 3-23 分段线性拉伸原理

2) 直方图均衡化

直方图均衡化是对图像直方图的改变, 对图像中的所有灰度值进行归一化处理^[48], 然后根据处理后的灰度值修正待处理图像中的像素。但该算法可能会造成图像部分信息的缺失。

直方图均衡化过程分析:

设原始图像的灰度级和均衡化后的灰度级分别为 r 和 s , 然后对 r 和 s 进行归一化, 归一化后灰度级分布在 $0 \leq r \leq 1$, 对 $[0,1]$ 区间内的任一个 r 值进行如下变换:

$$s = T(r) \quad (3-24)$$

式 3-24 应满足条件: (1) 对于 $0 \leq r \leq 1$, 有 $0 \leq s \leq 1$; (2) 在 $0 \leq r \leq 1$ 区间内。

其中, 从 s 到 r 的反变换用下式表示:

$$r = T^{-1}(s) \quad (3-25)$$

r 的概率密度为 $P_r(r)$, s 的概率密度可由 $P_r(r)$ 求出:

$$P_s(s) = \left(P_r(r) \frac{dr}{ds} \right) \Big|_{r=T^{-1}(s)} \quad (3-26)$$

假定变换函数为

$$s = T(r) = \int_0^r P_r(\omega) d\omega \quad (3-27)$$

式中, ω 是积分变量, $\int_0^r P_r(\omega) d\omega$ 是 r 的累积分布函数。

对式中的 r 求导, 得


$$\frac{ds}{dr} = \frac{dT(r)}{dr} = P_r(r) \quad (3-28)$$

再把结果代入前面公式, 得

$$P_s(s) = \left[P_r \cdot \frac{dr}{ds} \right]_{r=T^{-1}(s)} = \left[P_r \cdot \frac{1}{ds/dr} \right]_{r=T^{-1}(s)} = \left[P_r(r) \cdot \frac{1}{P_r(r)} \right] = 1 \quad (3-29)$$

由式 3-29 可知, 经变换后的变量是均匀分布的。

如图 3-24 所示为分段线性拉伸和直方图均衡化的结果对比。从结果可以看出直方图均衡化损伤了一些图像的细节, 增加了对后续处理的干扰; 而灰度拉伸有效地增加了各部分的对比度, 突出了损伤。






图 3-24 2 种图像增强方法结果对比

3.2.4 基于优化灰度拉伸算法的图像增强方法

找到待处理图像的灰度值的最大值和最小值；确定拉伸后的灰度范围；遍历灰度图像得到拉伸后的灰度图像。步骤如下：

- 1) 确定图像中灰度值的最大值 G_5 和最小值 G_1 ，以及数量最多的灰度值 G_3 ；
- 2) 确定灰度值 G_3 前的第一个极小值 G_2 和灰度值 G_3 后的第一个极大值 G_4 ；
- 3) 分别以 G_2 、 G_4 和 G_5 为窗顶，以 G_1 、 G_2 和 G_4 为窗底，对图像进行增强，可以表示如下：

$$G' = \begin{cases} \alpha \cdot \frac{G_1 + G_2}{2}, & G < G_2 \\ \beta \cdot \frac{G - G_2}{2} + G_2, & G_2 \leq G < G_3 \\ \gamma \cdot \frac{G_4 - G}{2} + G_3, & G_3 \leq G < G_4 \\ \lambda \cdot \frac{G_4 + G_5}{2}, & G > G_4 \end{cases} \quad (3-30)$$

其中， $0 < \alpha, \beta, \gamma, \lambda \leq 1$ ， G 和 G' 分别为拉伸前、后图像中像素的灰度值。





图 3-25 优化后灰度拉伸原理图


分别在四个灰度区间进行灰度拉伸，优化前后的结果如图 3-25 和图 3-26 所示：



(a) 线性拉伸

(b) 改进的灰度拉伸

图 3-26 分段线性拉伸优化前后结果对比



(a) 线性拉伸

(b) 改进的灰度拉伸

图 3-27 分段线性拉伸优化前后结果对比

从以上结果对比可以看出，优化后的灰度拉伸算法更好的突出了裂痕损伤，

把损伤和背景更好的分离了出来，增强了损伤部位的显示比度。灰度拉伸的结果好坏会影响到后续的相关处理步骤，清晰、噪声少的图像更易于处理。

3.3 本章小结

本章对幕墙单元面板图像进行了提取和预处理工作。

通过对比四种灰度化方法的处理结果，对处理后的图像质量进行了评价，确定了加权平均值法有更良好的效果；在 Harris 检测的基础上融合了 Hough 检测，更准确的获得了幕墙面板的角点位置，进而由透视变换提取出幕墙单元面板图像，减少了边框对损伤检测的干扰和运算量，简化了后续的损伤检测过程。

图像预处理过程包括滤波去噪和图像增强。通过理论对比，选用对孤立点消除效果更好的中值滤波，在融合了优化的冒泡算法后，更快的提取出了需要的中值，缩短了算法的运行时间；通过分段线性拉伸和直方图均衡化的结果对比，选用了效果较好的分段线性拉伸方法对图像进行增强，然后在此基础上进行了优化，更好地突出了损伤，增强了损伤的显示比度，改善了损伤处理的效果，为后续的步骤提供了更易于处理的图像。

第四章 幕墙面板的损伤检测方法

本章在幕墙单元面板图像的提取和预处理的基础上，对处理的图像进行边缘检测，边缘检测的结果即为需要检测的损伤。通过对传统边缘检测方法的优化，准确提取了损伤边缘，为后续的处理提供了保障。

4.1 边缘检测算子比选

边缘检测的结果为图像中灰色突变的部分，即为损伤，准确提取损伤边缘是幕墙面板损伤检测的基础，因此可以将幕墙面板图像中是否存在灰色突变作为损伤提取的依据。

在图像检测中，边缘通常是图像中局部变化最明显的部位，如灰度的突变、纹理结构的突变、表面方向的不连续等^[49]。近 20 多年来国内外转接提出了许多边缘检测算子，常见的有以下几种：Roberts 算子、Sobel 算子、Laplacian 算子、Canny 算子和 SUSAN 算子^[50]。

1) Roberts 算子

该算子通常用来处理低噪声图像，当图像边缘接近于 45 度或负 45 度时，该算法处理效果更理想^[51]，该算子的模板分为水平和垂直两个方向，表达式如式 4-1 所示，其中 d_x 表示水平方向， d_y 表示垂直方向。

$$d_x = \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix}, d_y = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix} \quad (4-1)$$

如图 4-1 所示为该算子模板在像素点 P5 处 x 和 y 方向上的梯度大小，表达式如式 4-2 所示：

$$\begin{aligned} g_x &= \frac{\partial f}{\partial x} = P9 - P5 \\ g_y &= \frac{\partial f}{\partial y} = P8 - P6 \end{aligned} \quad (4-2)$$




图 4-1 Roberts 算子模板

2) Sobel 算子

该算子结合了高斯平滑和微分求导,得到的结果有更好的抗噪性能,常用于灰度变化缓慢、噪声较多的图像^[52]。通常该算子用于在图像要求精度不高的情况。与其他几类不同的是,该算子中加入了权重,权重的大小与像素点和相邻点的距离有关,距离越近,权重越大,反之则越小。

算子模板如式 4-3 所示,其中 d_x 表示水平方向, d_y 表示垂直方向。

$$d_x = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}, d_y = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix} \quad (4-3)$$

如图 4-2 所示为该算子的模板,其在像素点 P5 处 x 和 y 方向上的梯度大小为:

$$\begin{aligned} g_x &= \frac{\partial f}{\partial x} = (P7 + 2P8 + P9) - (P1 + 2P2 + P3) \\ g_y &= \frac{\partial f}{\partial y} = (P3 + 2P6 + P9) - (P1 + 2P4 + P7) \end{aligned} \quad (4-4)$$




图 4-2 Sobel 算子模板

3) Laplacian 算子

该算子基于灰度差分计算邻域内的像素，常用于图像增强和边缘提取^[53]。处理步骤如下：（1）比较图像中心像素的灰度值与周围值的大小，若中心像素值大，则降低中心像素值，反之则升高；（2）对四邻域或八邻域中心像素进行梯度运算，进行累加后，再比较与其他像素的灰度值的关系；（3）最后通过上一步的结果对像素灰度值进行调整。

算子中的四邻域是对邻域中心像素的四个方向求梯度，八邻域是对八个方向求梯度。其四邻域模板如式 4-5 所示：

$$H = \begin{bmatrix} 0 & -1 & 0 \\ -1 & 4 & -1 \\ 0 & -1 & 0 \end{bmatrix} \quad (4-5)$$

八邻域模板如式 4-6 所示：

$$H = \begin{bmatrix} -1 & -1 & -1 \\ -1 & 8 & -1 \\ -1 & -1 & -1 \end{bmatrix} \quad (4-6)$$

通过模板可以发现：模板的卷积运算结果有 0、负数和正数三种情况。若邻域内像素的灰度值相同，则结果为 0；若中心像素值低，则结果为负数；若中心像素值高，则为正数。在原中心像素的基础上，加上经过衰弱因子处理的卷积结果，就可以实现图像的锐化处理。

4) Canny 算子

该算子的处理过程可以分为以下五步：（1）用高斯滤波器对图像进行平滑操作；（2）用一阶偏导的有限差分计算梯度的幅值和方向，找寻图像的强度梯度，该算子的卷积模板如式 4-7 所示，式 4-8 为其梯度幅值和方向；（3）对梯度幅值

进行非极大值抑制；（4）用双阈值算法检测和连接边缘^[54]。

$$d_x = \begin{bmatrix} -1 & 1 \\ -1 & 1 \end{bmatrix}, d_y = \begin{bmatrix} 1 & 1 \\ -1 & -1 \end{bmatrix} \quad (4-7)$$

$$\begin{cases} P(i, j) = (f(i, j+1) - f(i, j) + f(i+1, j+1) - f(i+1, j)) / 2 \\ Q(i, j) = (f(i, j) - f(i+1, j) + f(i, j+1) - f(i+1, j+1)) / 2 \\ M(i, j) = \sqrt{P(i, j)^2 + Q(i, j)^2} \\ \theta(i, j) = \arctan(Q(i, j) / P(i, j)) \end{cases} \quad (4-8)$$

5) SUSAN 算子

该算子通过比较圆形模板内的值与圆中心点值的大小，统计出与圆中心点值近似的像素点数量，并与预先设定的阈值进行比较，从而确定其是否为边缘^[55]。

定义一个半径为 3.4 个像素点的圆，圆的中心像素点称为模板的核。对于离散图像而言，这个圆共有 37 个像素点，如图 4-3 所示的深色部分即为离散圆。




图 4-3 SUSAN 圆形模板

在圆形模板内，将核值相似区面积（USAN）定义为与模板核像素值相似的像素点数量或面积，如图 4-4 所示的深色部分为面积，当圆形模板在待处理的图像上移动时，会有四种不同的情况：当模板与背景完全重合时，其面积最大，如图 4-4（a）所示；当模板向图像边缘移动时，其面积渐渐变小，如图 4-4（b）所示；当模板位于边缘时，其面积为原来的一半，如图 4-4（c）所示；当模板位于角点时，其面积最小，如图 4-4（d）所示。




图 4-4 USAN 的典型区域

检测过程如下：

1) 当模板在被检测的图像上移动时，比较模板内的像素值与核像素值，判断函数如式 (4-9) 所示：

$$c(r, r_0) = \begin{cases} 1, & |I(r) - I(r_0)| \leq t \\ 0, & |I(r) - I(r_0)| > t \end{cases} \quad (4-9)$$

其中， r_0 表示模板中心的位置； r 表示模板内其他位置； $I(r_0)$ 表示 r_0 处的像素值； $I(r)$ 表示 r 处的像素值； t 为阈值。

2) 当模板圆内的所有像元比较完成后，将结果累加，即

$$n(r_0) = \sum_{r \in D(r_0)} c(r, r_0) \quad (4-10)$$

其中， $n(r_0)$ 就是模板核在 r_0 处模板内图像 USAN 的像元数量， $D(r_0)$ 是以 r_0 为中心的圆形模板区域。

3) 如判断函数式 4-11 所示，若某个像素点的面积值小于设定的阈值，则被检测为角点，其中 g 通常设定为 USAN 最大面积的一半。

$$R(r_0) = \begin{cases} g - n(r_0), & n(r_0) < g \\ 0, & n(r_0) \geq g \end{cases} \quad (4-11)$$

4) 基于非极值抑制，对得到的角点利进行筛选，求得最后的角点。

在数字图像中，只能用近似圆代替圆形模板。门限 g 的选取，可能会影响边缘点的检测结果，通常选取 5×5 或 37 像素模板。若门限 g 的设定太小，则可能会漏检；若设定太大，则边缘周围的像素有可能被提取出来，导致提取的边缘范围过大；若选取过小则可能会漏检。通常 g 取 $0.75 \times n_{\max}$ (n_{\max} 为模板的最大的面积值) 时，提取出的边缘点较准确。

表 4-1 所示为各种算子的优缺点对比。

表 4-1 几种算子的优缺点对比

算子	优缺点对比
Roberts 算子	对垂直边缘和具有陡峭的低噪声的图像的检测效果好；对噪声较敏感，提取的边缘线条比较粗。
Sobel 算子	常用于噪声较多，灰度渐变的图像；对灰度的变化不敏感，对边缘的定位准确。
Laplacian 算子	对图像中的阶跃性边缘点定位准确；对噪声较敏感，容易造成边缘的不连续；可以用在模糊检测任务上。
Canny 算子	不容易受噪声干扰，容易让高频边缘被平滑掉，从而造成边缘丢失。
SUSAN 算子	抗噪能力好；算法使用灵活；运算量小，速度快；可以很好的检测边缘的方向信息。

以上几种算子的边缘检测结果如图 4-5 所示：




图 4-5 边缘检测结果对比

通过以上几种边缘检测算子的对比，可以发现 Roberts 算子的处理结果显示的线条较粗，Sobel 算子和 Canny 算子检测出的边界较为清晰，Laplacian 算子对损伤的检测较弱且识别不清晰，丢失了部分边缘，Roberts 算子和 SUSAN 算子的检测效果相对较好，处理结果较清晰。相比之下，SUSAN 算子的检测结果较为理想，结果清晰且后续处理容易。因此，选用 SUSAN 算子进行损伤的检测。

4.2 基于 SUSAN 算子的损伤检测方法

4.2.1 区域分裂合并算法

区域分裂合并算法是一种图像分割算法，处理的结果是将图像中灰度值相差较大的区域分割开，然后将相似的区域合并到一起。这种分裂和合并是按照某一种一致性准则进行的。主要算法流程如下：将图像分为四个子块，对比各个子块的灰度值，若相同则不需要继续分裂，反之继续将子块分为四个子块，当分裂到一定程度时就停止；比较分裂后相邻子块的灰度值，若相同则将其合并，反之则不合并；如此循环往复进行分裂和合并，直到不再有新的分裂与合并为止^[56]。图 4-6 所示为其分裂合并原理，图 4-7 所示为与之对应的四叉树结构。




图 4-6 区域分裂合并算法原理




图 4-7 相应的四叉树结构

该算法的难点在于分裂与合并的准则并不好判断，该准则又称为均匀性测试准则，用于判断该块图像是否需要分裂。目前常用的是统计检验（均方误差最小、F 检测等）。

本文采用均方误差最小准则^[57]作为判断准则，计算过程如下：

1) 计算平均值：

$$c = \frac{1}{N} \sum_{(x,y) \in \Omega} f(x,y) \quad (4-12)$$

其中， c 是区域 Ω 中 N 个点的平均值， $f(x,y)$ 为可以理解区域 Ω 中点 (x,y) 的灰度值。

2) 计算均方差：

$$s_n^2 = \frac{1}{N} \sum_{(x,y) \in \Omega} [f(x,y) - c]^2 \quad (4-13)$$

设定一个阈值，判断均方差大于这个值时就进行分裂。该算法具有一定的连续性，对一些边界的噪声能很好的滤除。

4.2.2 融合 SUSAN 算子和区域分裂合并算法的损伤检测方法

通过比较几种常用的边缘检测算子，选用检测效果较好的 SUSAN 算子，然后融合区域分裂合并算法对幕墙面板损伤图像进行边缘检测，得到了很好的检测效果，检测结果如图 4-8 所示。经过优化后的 SUSAN 边缘检测算子对损伤检测的连续性、完整性和准确性都明显提高。




图 4-8 优化前后 SUSAN 边缘检测算子的比较

评价一幅图像的好坏，最直观的是人的视觉感受。在没有图像参考的评价中，图像的清晰度是最常用的参考标准。目前比较常用的参考标准有方差函数、熵函数、灰度方差函数、能量梯度函数等。下面对部分函数做简要介绍。

1) 方差函数

定义如下：

$$D(f) = \sum_y \sum_x |f(x, y) - \mu|^2 \quad (4-14)$$

其中， μ 为图像的平均灰度值。该函数对噪声敏感，函数值越小，图像越好。

2) 熵函数

熵函数衡量了图像含有的信息丰富程度，其定义如下：

$$D(f) = -\sum_{i=0}^{L-1} p_i \ln(p_i) \quad (4-15)$$

其中， p_i 是灰度值为 i 的像素出现的频率， L 为灰度级总数（通常为 256）。根据 Shannon 信息论，熵最大时信息量最多^[58]，即熵越大则图像越清晰。

上述几种检测算子处理结果的方差函数和熵函数的值如表 4-2 所示。

表 4-2 几种处理结果的评价对比

	Roberts	Sobel	Laplacian	Canny	SUSAN	优化后 SUSAN
方差	1.5318e+04	1.5009e+04	1.8208e+04	1.4142e+04	1.6064e+04	1.4649e+04
函数						
熵函	1.2847	1.4818	2.4695	1.2788	1.4105	1.1287
数						

由表 4-2 可知，优化后的 SUSAN 算子的熵函数最小，说明图像中的除损伤外的其他信息量最少，很好的去除了多余的干扰；而方差函数的值也相对较小，说明图像中的噪声较少且图像更清晰。由此可见，优化后的算法得到的结果在清晰度和对比度上都较好，更好的提取了损伤。

4.3 本章小结

本章基于边缘检测的方法对幕墙面板的损伤进行了提取，并对提取结果进行了评价。分析比较了几种传统边缘检测算子的处理结果，选用了处理结果较好的 SUSAN 算子。针对结果呈现的清晰性等问题，对 SUSAN 算子进行了优化。在原有的基础上融合了区域分裂合并算法，对其中的一些干扰和噪点进行了滤除，优化后的结果相较之前，损伤的显示比度更大，更清晰，干扰更少。最后，对几种边缘检测算子得到的结果进行了质量评价，结果表明优化后的 SUSAN 算子在清晰度和对比度上较其他几种更好，同时更好的突出了损伤。

第五章 幕墙面板的损伤类型识别方法

本章在幕墙面板损伤提取的基础上，基于第二章的幕墙面板损伤特征，将提取的损伤特征送入向量机进行分类，从而实现幕墙面板的损伤识别。最后通过对像素点的计算得出损伤的面积估计值，可以作为损伤程度的参考。

5.1 幕墙面板损伤分类

5.1.1 支持向量机理论

利用用基于支持向量机的方法对幕墙面板的损伤进行分类。支持向量机是基于统计学习理论的二分类算法。支持向量机在很多领域都得到了广泛应用，尤其是是在分类问题上，其不会涉及应用领域的知识，但仍能提供很好的泛化性能，这是支持向量机特有的^[59]。

支持向量机的分类步骤如图 5-1 所示。主要过程为训练过程和分类过程。首先提取训练集的图像特征，将提取的特征送入向量机进行学习，构造合适的分类器；然后对测试集进行分类，从而得到分类结果。

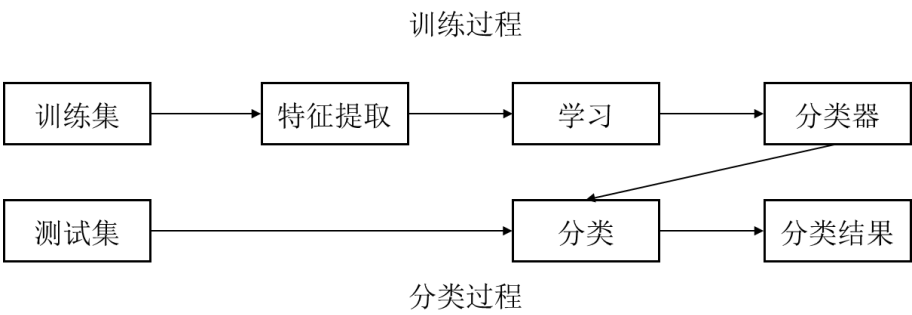


图 5-1 支持向量机分类步骤

SVM 主要用来解决二分类的问题。如果是二维平面，则要寻找一条直线将两类分开，目的是在众多直线中找到鲁棒性能最好的那一条。如果是三维空间，则要找到一个最优分类平面；如果是超过三维以上的维数，则要找到一个最优分类超平面。支持向量机的目标就是找到这个超平面。如图 5-2 是二维空间中最优超平面的几何结构^[60]。




图 5-2 SVM 二维分类模型

支持向量机分为两种情况：线性可分和线性不可分。

1) 对于线性可分的情况，需找到各类样本点到超平面的最短距离，其中任意超平面线性方程为：

$$\omega^T x + b = 0 \quad (5-1)$$

$\omega = (\omega_1, \omega_2, \dots, \omega_m)$ 为超平面的法向量，决定了超平面的方向； m 为样本点个数； b 为超平面平移，决定了超平面距原点的距离。样本集需要满足：

$$y_i(\omega^T x_i + b) - 1 \geq 0, i = 1, \dots, m \quad (5-2)$$

样本点到超平面的距离为：

$$d(x, \omega, b) = \frac{|\omega^T x + b|}{\|\omega\|} \quad (5-3)$$

式中 $\|\omega\| = \sqrt{\omega^T \cdot \omega}$ 。靠近临界点的样本点满足：

$$|\omega^T x_i + b| = 1 \quad (5-4)$$

综合两式，可以得出样本点到超平面的距离为 $\frac{1}{\|\omega\|}$ ，从而得出，空间中最大的线

性分开两类数据的分类间隔为 $\frac{2}{\|\omega\|}$ 。若要使间隔最大化，需要满足公式：

$$\begin{cases} \max_{\omega, b} \frac{2}{\|\omega\|} \\ s.t. \quad y_i(\omega^T x_i + b) \geq 1, i = 1, 2, \dots, m \end{cases} \quad (5-5)$$

最大化的 $\frac{2}{\|\omega\|}$ 即是最小化的 $\|\omega\|$ ，上式可以转换为

$$\begin{cases} \min_{\omega, b} \frac{1}{2} \|\omega\|^2 \\ s.t. \quad y_i(\omega^T x_i + b) \geq 1, i = 1, 2, \dots, m \end{cases} \quad (5-6)$$

引用拉格朗日乘子，将两个参数的优化问题转化为一个参数的优化问题。其拉格朗日函数如下：

$$L(\omega, b, \alpha) = \frac{1}{2} \|\omega\|^2 + \sum_{i=1}^m \alpha_i (1 - y_i(\omega^T x_i + b)) \quad (5-7)$$

其中 α_i 为拉格朗日乘子，令 $L(\omega, b, \alpha)$ 对 ω 和 b 的偏导为零，可得

$$\begin{cases} \omega = \sum_{i=1}^m \alpha_i y_i x_i \\ 0 = \sum_{i=1}^m \alpha_i y_i \end{cases} \quad (5-8)$$

将式 5-8 中的 ω 代入式 5-7，得到求解最优分类面问题的对偶问题：

$$\begin{cases} \max \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j (x_i^T x_j) \\ s.t. \quad 0 = \sum_{i=1}^m \alpha_i y_i \\ s.t. \quad \alpha_i \geq 0, i = 1, \dots, m \end{cases} \quad (5-9)$$

对偶问题^[61]是在不等式条件约束下的二次函数寻优问题，存在唯一解。求解上述问题后得到的最优分类函数如式（5-10）所示，式中 b 为分类阈值：

$$\begin{aligned} f(x) &= \text{sgn}(\omega^T x + b) = \text{sgn}\left(\left(\sum_{i=1}^m \alpha_i y_i x_i^T\right) \cdot x + b\right) = \\ &\text{sgn}\left(\sum_{i=1}^m \alpha_i y_i (x_i^T \cdot x) + b\right) \end{aligned} \quad (5-10)$$

2) 对于线性不可分的情况，引入松弛因子 ξ ，目的是允许存在少量的样本错误分类，此时，式 5-2 变为：

$$y_i(\omega^T x_i + b) - 1 + \xi_i \geq 0, i = 1, \dots, m \quad (5-11)$$

此时的最小值变为:

$$\frac{1}{2}\|\omega\|^2 + C\sum_{i=1}^m \xi_i \quad (5-12)$$

式 5-12 中, C 是一个大于零的常数, 为惩罚因子。求解对偶问题时, 与线性可分情况下的不同之处为: $\alpha_i \geq 0, i=1, \dots, m$ 变为 $0 \leq \alpha_i \leq C, i=1, \dots, m$ 。

为了解决高维维度计算量大的问题, 引入了核函数。核函数的意义是在低维上进行计算, 而将实质上的分类效果表现在了高维上, 从而避免了在高维空间中的大量计算, 真正解决了 SVM 线性不可分的问题^[62]。比较常见的核函数有以下几种:

(1) 线性核函数:

$$K(X, Z) = (X \cdot Z) \quad (5-13)$$

式中, X 为样本中的随机向量, Z 为样本的支持向量。

(2) q 次多项式核函数:

$$K(X, Z) = [(X \cdot Z) + 1]^q \quad (5-14)$$

该核函数适用于正交归一化数据, 参数 q 越大, 映射的维度越高, 相应的计算量也会越大, 易出现“过拟合”。

(3) 径向基核函数 (高斯核):

$$K(X, Z) = e^{-\gamma\|X-Z\|^2} \quad (5-15)$$

该核函数也可以表式为另一种形式:

$$K(X, Z) = e^{-\frac{\|X-Z\|^2}{2\sigma^2}} \quad (5-16)$$

该核函数是局部核函数, 也是应用最广的一个, 对噪声有着较好的抗干扰能力。

(4) Sigmoid 核函数:

$$K(X, Z) = \tanh[\gamma(X \cdot Z) + r] \quad (5-17)$$

Sigmoid 核来源于神经网络, 现已大量应用于深度学习和机器学习中。其中 r 为根据实际情况取值的常数。

在支持向量机中要选择合适的核函数构造分类器对图像进行训练, 为了分类结果的准确性, 训练集不能有错误的样本, 且要有一定的代表性。本文采用高斯径向基核函数, 从而得到径向基函数分类器。

5.1.2 基于 SVM 的幕墙面板损伤类型识别

(1) 损伤特征提取

主要思想是将输入的非线性特征转换为线性特征，线性特征维数越高，对目标特征的描述越准确。网络模型如图 5-3 所示。




图 5-3 SVM 特征提取网络模型

幕墙面板损伤特征的提取是利用 SVM 进行训练和分类的依据，合理的选取特征是损伤分类的保证。幕墙面板热炸裂损伤通常为细长弯曲的不规则形状，走向与分布都不规律，而自爆和外力冲击的分布、面积大小和位置都不规律，但灰度差比较明显。为此本文选取了以下特征构造特征向量。

1) 灰度差

图像灰度值记录了图像明暗。图像像素点越亮则灰度值越高，相反则表示灰度值越低，可以求取图像上的最大灰度值和最小值灰度差作为特征。

2) 最大方差

区域的平均灰度也是常用的灰度特征之一，反应了图像表面的灰度变化幅度，缺陷区域面积较小，对整体区域求取方差将会抵消缺陷区域的灰度变化，对损伤图像求取灰度均值和方差。

3) 方向梯度直方图（HOG）

方向梯度直方图是由图像局部的梯度方向直方图构成的特征，广泛应用于图像处理领域。提取过程包括以下五个步骤^[63]：第一，对图像进行归一化处理，增加对光照度变化的稳定性；第二，计算图像梯度，表达式如式 5-12 所示：

$$\begin{cases} G_x(x, y) = H(x+1, y) - H(x-1, y) \\ G_y(x, y) = H(x, y+1) - H(x, y-1) \\ G(x, y) = \sqrt{G_x(x, y)^2 + G_y(x, y)^2} \\ \alpha(x, y) = \tan^{-1}\left(\frac{G_y(x, y)}{G_x(x, y)}\right) \end{cases} \quad (5-12)$$

其中, $G_x(x, y)$ 、 $G_y(x, y)$ 、 $H(x, y)$ 分别表示当前像素点的水平梯度、垂直梯度和像素值, $G(x, y)$ 、 $\alpha(x, y)$ 分别为当前像素点的梯度幅值和梯度方向; 第三, 构造细胞单元的梯度方向直方图; 第四, 将第三步中的细胞单元进行组合, 对组合后的块进行归一化, 表示式如式 5-13 所示:

$$V = \frac{v}{\sqrt{\|v\|_2^2 + \varepsilon^2}} \quad (5-13)$$

其中, v 是未经归一化的描述子向量, ε 是一个极小的常数; 第五, 收集特征, 如图 5-4 所示, 利用滑动窗口对样本图像进行扫描, 窗口的大小为一个块, 扫描步长为一个细胞单元 (cell), 所以总共有 $(64/8) - 1 = 7$ 个水平位置和 $(128/8) - 1 = 15$ 个竖直位置, 所以有 $7 \times 15 = 105$ 个不同位置的块。每一个 16×16 的块被表示为一个 36×1 的向量, 因此, 最后把所有归一化后的块特征串联起来就得到 $36 \times 105 = 3780$ 维特征向量。




图 5-4 方向梯度直方图构建

4) 灰度共生矩阵 (GLCM)

灰度共生矩阵是一个矩阵函数, 其包含了像素距离和角度, 反映了图像的变化方向、变化幅度等综合信息, 也反映了图像的位置分布特征, 同时也是计算纹理特征的基础。

灰度共生矩阵表述的是在指定距离和方向上相同灰度值的像素对的个数，其对角线上数值的大小反映了图像纹理变化的快慢，由于其数据量很大，通常由其构造一些统计量进行特征分类。下面对常用的三种做简要介绍：

能量（ASM）可以度量图像灰度分布^[64]，表述的是均匀程度和纹理粗细。当图像纹理均匀规则时，能量值较大；反之能量值较小。表达式如式 5-14 所示。

$$ASM = \sum_i \sum_j P(i, j)^2 \tag{5-14}$$

熵（ENT）反映了图像信息量的随机性，表述了图像的复杂程度^[65]。当矩阵中所有值均相等或随机性最大时，熵最大。表达式如式 5-15 所示。

$$ENT = - \sum_i \sum_j P(i, j) \log(P(i, j)) \tag{5-15}$$

相关性（CORR）表述的是图像的纹理特征，以度量图像灰度级在方向上的相似程度，反映了图像中局部灰度的相关性^[66]。当矩阵值均匀相等时，值越大，表明相关性大；反之就小。表达式如式 5-16 所示。

$$CORR = \frac{\sum_i \sum_j ((i, j)P(i, j)) - \mu_x \mu_y}{\sigma_x \sigma_y} \tag{5-16}$$

（2）损伤特征样本库的建立

好的样本库的建立是提高分类识别准确性的关键步骤。从三种典型损伤图像中提取其损伤特征，建立损伤特征样本库。部分图像的部分特征统计量如表 5-1 至 5-4 所示。

表 5-1 幕墙面板损伤均值和方差特征样本库（部分）

类型	序号	均值	方差
自爆	1	134.0815	3.2563e+03
	2	95.8951	2.0518e+03
	3	90.4145	4.0096e+03
外力冲击	1	129.0169	596.4447
	2	165.6705	361.0092
	3	14.7199	1.3920e+03
热炸裂	1	160.0680	2.0375e+03
	2	177.8937	1.0063e+03
	3	180.1974	1.1746e+03

图像的方差越大表明其所包含的信息越多,图像越复杂;均值表示图像的灰度值平均值,是图像的亮暗程度的表示。

表 5-2 幕墙面板损伤能量特征样本库(部分)

类型	序号	0°	45°	90°	135°
自爆	1	0.034108	0.029649	0.036999	0.031692
	2	0.062235	0.049538	0.060929	0.061880
	3	0.049784	0.044005	0.050919	0.045275
外力冲击	1	0.144249	0.110469	0.126174	0.115744
	2	0.211841	0.151846	0.165766	0.172115
	3	0.549738	0.495223	0.526500	0.530276
热炸裂	1	0.888313	0.878146	0.887860	0.884389
	2	0.580550	0.561047	0.598492	0.551021
	3	0.461281	0.454342	0.466650	0.448205

图像中的能量特征值越大,表明图像的灰度分布越均匀且纹理变化规则,且相较于其他类型易识别。

表 5-3 幕墙面板损伤熵特征样本库(部分)

类型	序号	0°	45°	90°	135°
自爆	1	3.907399	4.0444614	3.822634	4.008364
	2	3.641267	3.921975	3.690127	3.577414
	3	3.739030	3.902741	3.684239	3.841003
外力冲击	1	2.326539	2.558964	2.435628	2.532614
	2	1.596670	2.260735	2.164191	2.117891
	3	1.703783	1.838319	1.767833	1.759029
热炸裂	1	0.317135	0.346285	0.318086	0.329824
	2	1.093913	1.155610	1.065793	1.219171
	3	1.053254	1.054388	1.035647	1.099444

图像中的熵特征值越大,表明图像越复杂,包含的信息越多,在后续的处理过程中是识别类型的一个重要特征。




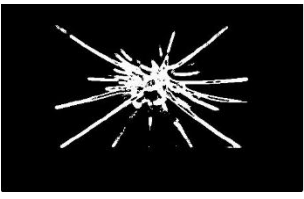
表 5-4 幕墙面板损伤相关性特征样本库（部分）




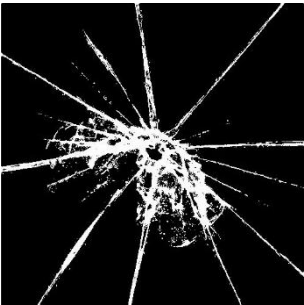

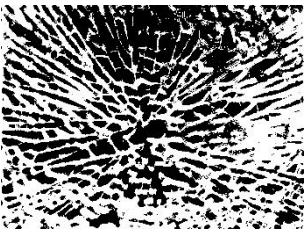

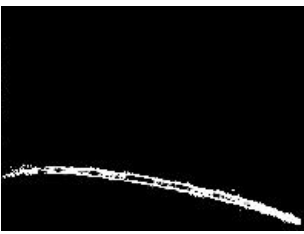
类型	序号	0°	45°	90°	135°
自爆	1	0.134919	0.124058	0.139814	0.125815
	2	0.109546	0.072676	0.104935	0.117114
	3	0.104303	0.096180	0.106517	0.101176
外力冲击	1	0.750952	0.638781	0.711895	0.654611
	2	0.899607	0.783695	0.822748	0.841568
	3	0.146065	0.102171	0.131722	0.132347
热炸裂	1	15.907745	13.018342	15.844880	14.699820
	2	1.690804	1.583154	1.592935	1.247521
	3	2.010217	2.395292	1.905355	1.507832

5.1.3 损伤类型识别实验与结果分析

对三种损伤类型图像和无损伤图像进行了特征提取，将其作为训练集的输入进行训练，得到训练模型，最后，对样本进行损伤种类识别，部分结果如表 5-5 所示。

表 5-5 幕墙面板损伤识别结果（部分）

玻璃幕墙	损伤	识别结果
		识别结果为热炸裂
		识别结果为外力冲击

		识别结果为自爆， 实际上为外力冲击
		识别结果为外力冲击
		识别结果为自爆
		识别结果为热炸裂

由于外力冲击和自爆的损伤分布没有规律，且若是大范围的外力冲击导致边缘损伤加剧，有可能会被识别为自爆，外力冲击中心的灰度差是区分损伤的关键。热炸裂所造成的裂纹损伤就较容易识别出来，与损伤边缘提取的效果有一定的关系。

由识别结果得知，因热炸裂引起的裂纹损伤在经过边缘检测的处理后，很好的被识别出来，因此边缘检测算法的准确性与裂纹识别的准确性有一定的关系。而自爆和外力冲击引起的损伤因损伤部位、损伤程度的不同容易造成误检，但这两种损伤更容易在平时被发现而及时替换，若将识别种类分为损伤和非损伤，自爆损伤和外力冲击损伤在损伤特征数据上有部分相似之处，若自爆不明显或外力冲击严重，则可能会识别为错误种类，但识别结果仍是损伤，所以无法定量的评价本方法对玻璃幕墙损伤分类的准确率，识别的准确性除了与分类器本身的

性能有关外，还与边缘检测的效果有关。从结果看，该方法对幕墙面板损伤类型的识别效果良好。

5.2 幕墙面板损伤参数计算

因为本文是基于表面检查法进行的损伤检测，所以对损伤的深度无法进行定量的计算，因此本文主要对损伤的表面面积进行了测量，针对玻璃幕墙单元面板图像，利用的是损伤部位的像素点与总像素点的数量关系。首先计算图像中总的像素点个数，然后对损伤部位的像素点个数进行计算，通过损伤部位像素点的个数占比，可以求得损伤部位的面积占比。

由于对图像损伤检测的准确性，可能会将损伤边缘部位的毛刺等一并算入损伤面积，这将影响面积计算的准确性，因此，本文计算的损伤表面面积仅作为质量评价的参考。其实际的面积会略小于测量的面积。

如图 5-5 所示为损伤面积测量的结果。




图 5-5 损伤面积测量

由幕墙面板损伤图像中的像素关系，可以得出，图像的总像素点的个数为 71838，白色像素点即为损伤部位的个数为 1018，占整幅图像的比例为 1.42%，再通过幕墙面板的实际面积从而求的损伤的面积。

5.3 本章小结

本章是在对幕墙面板图像进行损伤提取的基础上，利用 SVM 分类方法对幕

墙面板损伤进行类型识别,并利用像素点的比例关系进行了损伤面积测量,然后用 Matlab 进行了编程实验,分析了实验效果。

基于图像的边缘检测,利用支持向量机的方法对图像的损伤进行识别,选取灰度差、最大方差、方向梯度直方图和灰度共生矩阵作为为分类特征,送入向量机进行训练,最后的识别结果表明,该方法对幕墙面板的损伤类型识别效果良好,但会受边缘检测结果的影响,干扰损伤类型识别的准确率。

基于图像像素点的数量关系,利用损伤部位的像素点个数占比,进而得出损伤部位的占比,然后利用面板图像与实际面板的比例关系,求出幕墙面板图像具体的损伤面积。损伤部位的面积测量在实际应用中仅起到参考作用。

第六章 结论与展望

6.1 结论

本文在分析了玻璃幕墙不同损伤类型特征的基础上，对损伤图像进行提取、预处理、损伤检测和损伤类型识别。通过对关键技术的研究，准确提取了幕墙面板单元图像，突出了图像的损伤，提升了幕墙面板损伤检测的准确性。研究结果如下：

（1）分析了玻璃幕墙的损伤特征

分析了玻璃幕墙自爆、热炸裂和外力冲击等不同损伤类型出现的位置分布。通过比较三种损伤类型的灰度直方图、方向梯度直方图和灰度共生矩阵特征，分析了三种损伤的纹理特征、灰度特征及图像复杂程度，并提取了相应的特征值做对比。提取的特征值可以用做后续类型识别的部分特征。因自爆导致的损伤通常在中心部位，呈放射状向外发散；因热炸裂导致的损伤多从边缘开始，且无规则向外延伸；因外力冲击导致的损伤通常表现为白色粉末状凹陷，同时以受力点为中心向外发散。

（2）对幕墙单元面板进行了提取和预处理

对几种常用的图像灰度化进行了结果比较，选用了处理效果较好的加权平均值法对幕墙图像进行了处理。首先对幕墙单元面板图像进行提取，在 Harris 检测的基础上结合 Hough 检测确定了幕墙单元面板的具体位置，进而利用透视变换提取出幕墙单元面板图像；然后对提取的单元面板图像进行预处理，包括滤波去噪和图像增强。在冒泡算法和中值滤波结合的基础上，对冒泡算法进行了优化，缩短了中值滤波的运行时间。最后为了增强对比度对图像进行了灰度拉伸，为了改善灰度拉伸的处理效果，对其进行了优化，增强了损伤的显示比度，更好的突出了缺陷。

（3）对幕墙单元面板的损伤进行了检测与类型识别

在图像预处理的基础上，对其进行损伤检测，采用边缘检测的方法，检测出的边缘即为损伤。通过对比几种常用的边缘检测算子，选用处理效果较好的 SUSAN 检测算子，然后针对 SUSAN 算子处理结果不清晰的问题，对其进行了

优化,在 SUSAN 算子的基础上融合了区域分裂合并算法,使得提取的损伤变得清晰连续,提高了损伤提取的准确率;在图像像素比的基础上计算损伤区域的面积,通过损伤部位像素点占图像总像素的面积,再由实际的物像比例计算损伤面积,对面积的测量可以用来参考损伤的程度大小;通过支持向量机的方法对损伤类型进行识别,提取了图像的灰度差、最大方差、方向梯度直方图和灰度共生矩阵的损伤特征,送入向量机进行训练,然后完成对幕墙面板损伤种类的识别,结果表明,该方法对幕墙面板的损伤类型识别效果良好,但会受边缘检测结果的影响,干扰损伤类型识别的准确率。

6.2 展望

本文主要运用机器视觉的方法,利用图像处理技术对幕墙单元面板图像进行了提取、预处理、损伤检测和分类等研究,符合现代社会人工智能、智慧建筑等发展趋势。但这些方法还存在不足,需要进一步研究和完善。

在幕墙面板损伤检测方面,对于一些比较浅的损伤,其灰度特征不明显,检测的结果可能不连续,有待于进一步研究;在幕墙面板损伤提取方面,可以考虑结合多特征融合的方法,提高幕墙面板损伤提取的准确率;在幕墙面板损伤分类方面,可以多选取几个其他特征指标,以便能更好地表述幕墙面板损伤特征。

随着智能化的进步,对高空幕墙的拍摄也应该进行深入研究。同时对高空幕墙的损伤深度、破坏程度检测的相关算法应该与深度学习相结合,以便于进行更高效安全的检测,不断提高幕墙面板损伤检测的智能化水平。

参 考 文 献

- [1] 前瞻产业研究院.2021-2026 年中国建筑幕墙行业市场前瞻与投资战略规划分析报告 [EB/OL].[<https://bg.qianzhan.com/report/detail/e84d476d660a419c.html>],2021-03-30.
- [2] 中华人民共和国建设部.GB50068-2018 建筑结构可靠度设计统一标准[S].北京: 中国建筑工业出版社,2018.
- [3] 张俊宝,郭新龙.装配式建筑幕墙施工技术[J].绿色环保建材,2021(12):109-110.
- [4] 崔静恩,彭明强,李锐等.光伏幕墙在建筑工程中的应用研究[J].城市建筑, 2021,18(29):54-56.
- [5] 林振. 超薄石材幕墙的粘贴技术及性能分析 [J].四川建材, 2021,47(12):248-249.
- [6] Tregonning R B K G . The Glass Curtain Between Asia and Europe.by Raghavan Iyer[J]. The Journal of Asian Studies, 1966, 25(4):739-741.
- [7] Wang Y . Historical Development and Future Prospects of Structural Silicone Sealants in China[J]. Journal of Astm International, 2004, 1(7):6.
- [8] 龙文志. 幕墙标准发布与幕墙行业发展概述——JG 3035、JGJ 102 发布十年有感[J]. 门窗, 2007(3):1-7.
- [9] 中国建筑科学研究院.JGJ 102-2003 玻璃幕墙工程技术规范[S].北京: 中国建筑工业出版社,2003.
- [10]四川省建筑科学研究院.DB51/T5068-2010 既有玻璃幕墙安全使用性能检测鉴定技术规程[S].四川: 四川省建设科技发展中心,2010.
- [11]天津市建筑科学研究院.DBT29-248-2017 天津市既有建筑幕墙可靠性鉴定技术规程范[S].天津: 天津市建设工程技术研究所,2017.
- [12]叶果,谢元勋,张洪川等. 无人机技术在建筑工程领域的应用[J].智慧城市, 2021,7(02):78-79.
- [13]蔡江东,陈亚东,蔡玥等. 3D 数字图像处理在红外影像鉴定外墙质量中的应用[J].城市住宅, 2016,23(08):84-86.
- [14]马国鑫,韩豫,陆建飞等. 基于无人机的施工扬尘污染源自动检测系统设计与实现[J].中国环境检测, 2018,34(01):151-156.
- [15]马国鑫,韩豫,孙佳宁等. 基于无人机的外脚手架安全性自动检查系统设计与实现[J].土木工程与管理学报, 2018,35(04):169-174.
- [16]陈睿, 李乃东. 现代高层建筑玻璃幕墙施工技术分析[J].住宅与房地产, 2020(30):89,93.

- [17]樊静静. 从传统建筑到智慧建筑,时代推动行业发展[J].中国建设信息化, 2019(04):63.
- [18]刘小根,包亦望,许海凤等. 基于光弹检测技术的真空玻璃真空度衰减率半定量评估 [C]/TEIM2015 第六届无机材料结构、性能及测试表征技术研讨会程序册与摘要集.2015:12.
- [19]顾琰斌. 夹层玻璃板损伤检测及评估[D]. 南京:东南大学, 2005.
- [20]刘小根. 玻璃幕墙安全性能评估及其面板失效检测技术[D]. 北京:中国建筑材料科学研究总院, 2010.
- [21]杨继亮,金永,王召巴. 基于线阵 CCD 的玻璃缺陷检测系统研究[J].传感器与微系统, 2011,30(11):25-27.
- [22]卢印举,郝志萍,戴曙光. 融合双特征的玻璃缺陷图像分割算法[J].包装工程, 2021, 42(23):162-169.
- [23]卢印举,段明义,苏玉. 一种改进的高斯混合模型的玻璃缺陷分割方法[J].仪表技术与传感器, 2021,(02):94-98+103.
- [24]张彩霞,陈晓荣,徐云洁等. 玻璃表面缺陷检测系统研究[J].包装工程, 2020,41(13):216-222.
- [25]王维,王杰,黄易杨等. 基于偏振透射结构光的透明物体表面缺陷检测方法[J].光学学报, 2021,41(18):1812002.
- [26]Gholizadeh S , Leman Z , Baharudin B T H T , et al. Acoustic emission analysis for characterisation of damage mechanisms in glass fiber reinforced polyester composite[J]. Australian Journal of Mechanical Engineering, 2016, 16(1):1-10.
- [27]Arumugam V,Saravanakumar K,Santulli C. Damage characterization of stiffened glass-epoxy laminates under tensile loading with acoustic emission monitoring[J]. Composites Part B: Engineering,2018, 147:22-32.
- [28]Malpot A, Touchard F, Bergamo S. An investigation of the influence of moisture on fatigue damage mechanisms in a woven glass-fibre-reinforced PA66 composite using acoustic emission and infrared thermography[J]. Composites Part B Engineering, 2017, 130.
- [29]Xin Zhao , Yahui Cao , Tao Zhang ,et al. An improve feature selection algorithm for defect detection of glass bottles[J]. Applied Acoustics,2021, 174.
- [30]Jisu Park , Hamza Riaz , Hyunchul Kim ,et al. Advanced cover glass defect detection and classification based on multi-DNN model[J]. Manufacturing Letters,2020,23:53-61.
- [31]Koichi Mizukami , Yoshihiro Mizutani , Akira Todoroki ,et al. Design of eddy current-based dielectric constant meter for defect detection in glass fiber reinforced plastics[J]. 2015,74:24-32.
- [32]Zhufeng Pan , Jian Yang , Xing-er Wang ,et al. Image-based surface scratch detection on architectural glass panels using deep learning approach[J]. 2021,282.

- [33]Yuan Yuan , Yifei Zhou , Wenbai Liu ,et al. Flexural deformation characterization of glass panel in curtain walls based on digital image correlation technique[J]. Construction and Building Materials,2020,260.
- [34]Yuan Yuan , Yifei Zhou , Lixin Wang ,et al. Coupled deformation behavior analysis for the glass panel in unitized hidden-frame supported glass curtain wall system[J]. Engineering Structures,2021,244.
- [35]Shigeki Sawamura , Rene Limbach , Harald Behrens ,et al. Lateral deformation and defect resistance of compacted silica glass:Quantification of the scratching hardness of brittle glasses[J]. Journal of Non-Crystalline Solids,2018,481:503-511.
- [36]国家发展和改革委员会,建设部.建筑安全玻璃管理规定[J].辽宁建材, 2004(1):3-4.
- [37]Ma K , Zhao T , Zeng K. Objective quality assessment for color-to-gray image conversion[J]. IEEE Transactions on Image Processing,2015,24(12):4673-4685.
- [38]陈杰. 基于色彩信息的图像增强研究[D]. 南京:南京邮电大学,2017.
- [39]蒋林峰. 基于条件随机场模型的目标检测方法研究[D]. 上海:上海交通大学,2019.
- [40]肖甫,吴慧中,肖亮. 一种光照鲁棒的图像拼接融合算法[J].中国图象图形学报,2007,12(9):1671-1675.
- [41]马颂德,张正友. 计算机视觉: 计算理论与算法基础[M].科学出版社,2004.
- [42]章毓晋. 图象工程-图象处理和分析[M].清华大学出版社,1999:72-98.
- [43]曹妍,陈伟,徐森. 图像去噪方法研究与仿真[J].软件, 2015,36(04):33-36.
- [44]Pratt W K. Median filtering[C]//In Seminar Report, Image Proc. Institute, Univ. of Southern California,1975,9:116-123.
- [45]王萍,孙绍功,高原等. 图像处理技术在焊缝跟踪中的应用[J].传感器世界,2007(08):26-29.
- [46]魏梦舒. 漫画算法[M].北京:电子工业出版社,2020.
- [47]李理. 基于多目视觉的批量工件在线检测技术[M].北京:科学出版社,2019.
- [48]何金国. 数字图像处理实训教程[M].北京:清华大学出版社,2008.
- [49]谢新华,梁栋,张香倩等. 基于图像处理的目标物体最大内接矩形面积的检测[J].科学技术与工程,2015,15(17):193-197+217.
- [50]王智文. 几种边缘检测算子的性能比较研究[J].制造业自动化,2012,34(11):14-16.
- [51]李军成. 图像边缘检测的分数阶微分算子研究[J].计算机应用与软件, 2015,32(12):206-209+221.
- [52]刘源,夏春蕾. 一种基于 Sobel 算子的带钢表面缺陷图像边缘检测算法[J].电子测量技术, 2021,44(03):138-143.
- [53]田素云,王小明,赵雪青. 基于拉普拉斯算子和图像修补的图像去噪算法[J].计算机应

- 用,2012,32(10):2793-2797.
- [54]吴韡,段发阶,段晓杰等. 基于图像处理技术的石油筛管割缝在线检测[J].电子技术应用,2014,40(04):120-122.
- [55]赵小川,何灏,缪远诚. MATLAB 数字图像处理实战[M].北京:机械工业出版社,2013.
- [56]刘耀林,丁名时. 基于四叉树原理的多波段遥感影像区域合并算法[J].测绘通报,2016,(02):32-37.
- [57]宋晓勤,李克,薛强等. 一种基于最小均方误差准则的联合多小区信道估计算法[J].电子与信息学报, 2007,(11):2589-2592.
- [58]张盈,张景雄. 顾及空间相关性的遥感影像信息量的度量方法[J].测绘学报, 2015,44(10):1117-1124.
- [59]王立国,赵亮,刘丹凤. SVM 在高光谱图像处理中的应用综述[J].哈尔滨工程大学学报, 2018,39(06):973-983.
- [60]Simon Haykin,叶世伟,史忠植. 神经网络原理[M].北京:机械工业出版社,2004.
- [61]刘红英,杨茜. 机器学习中的最优化模型与对偶[J].数学的实践与认识, 2017,47(04):225-233.
- [62]许献磊,李俊鹏,王亚文等. 基于支持向量机的道路地下空洞量化识别方法[J].工程勘察,2019,47(04):70-78.
- [63]金壮壮,曹江涛,姬晓飞. 多源信息融合的双人交互行为识别算法研究[J].计算机技术与发展,2018,28(10):32-36+43.
- [64]陈文睿,陈天华,王小艺等. 基于图像的皮肤纹理评价算法研究[J].日用化学工业, 2018, 48(12):695-701+710.
- [65]孙荣荣. 基于灰度共生矩阵相似图的图像质量评价方法[J].计算机应用, 2020,40(51):177-179.
- [66]李强,张景发,龚丽霞等. SAR 图像纹理特征相关变化检测的震害建筑物提取[J].遥感学报, 2018,22(51):128-138.

致 谢

行文至此，宣告着研究生生涯已接近尾声。回首三年，往事历历在目，颇为受益。

首先，感谢任杰老师的谆谆教诲，任老师为人和善，平易近人，在学业和生活上对我都关怀备至。从课题选择及阶段汇报，都会细心与我讨论并给出相应的建议。在我遇到难处时，任老师也会为我耐心讲解。任老师亦鼓励我多运动，这也使得我的压力得到了释放。非常感谢任老师三年的教诲，令我受益终身。

其次，感谢我的同门朱凯，他的学术能力很强，每每与他讨论，我都有所收获。同时感谢我身边的同学和朋友们，感谢 401 研修室的全体小伙伴们，是你们给三年的研究生时光增添了一抹亮色。

必须要感谢的是我的家人们，你们在背后无条件的鼓励和支持，才有了今天的我。在此向我的父母说一声，你们辛苦了。同时，感谢出现在我人生路上的所有人，谢谢你们！

最后，对参加论文评审和答辩的各位老师表示由衷的感谢！

